

# 引言:无约束优化算法

$$\min_{x \in \mathbb{R}^n} f(x).$$

- 线搜索

- ① 先确定搜索方向:梯度类算法、次梯度算法、牛顿算法、拟牛顿算法等.
- ② 按准则进行近似搜索.

- 信赖域

- ① 主要针对 $f(x)$  二阶可微的情形, 在一个给定的区域内使用二阶模型近似原问题.
- ② 不断直接求解该二阶模型从而找到最优值点.

# 线搜索算法:盲人下山

- 求解 $f(x)$  的最小值点如同盲人下山, 无法一眼望知谷底, 而是:
  - ① 首先确定下一步该向哪一方向行走.
  - ② 再确定沿着该方向行走多远后停下以便选取下一个下山方向.
- 线搜索类算法的数学表述:

$$x^{k+1} = x^k + \alpha_k d^k.$$

我们称 $d^k$  为迭代点 $x^k$  处的**搜索方向**,  $\alpha_k$  为相应的**步长**. 这里要求 $d^k$  是一个**下降方向**, 即 $(d^k)^T \nabla f(x^k) < 0$ .

- 线搜索类算法的关键是如何选取一个好的方向 $d^k \in \mathbb{R}^n$  以及合适的步长 $\alpha_k$ .

## $\alpha_k$ 的选取:精确线搜索算法

- 选取 $d^k$ 的方法千差万别,但选取 $\alpha_k$ 的方法却非常相似.
- 首先构造一元辅助函数

$$\phi(\alpha) = f(x^k + \alpha d^k),$$

其中 $d^k$ 是给定的下降方向, $\alpha > 0$ 是该辅助函数的自变量.

- 线搜索的目标是选取合适的 $\alpha_k$ 使得 $\phi(\alpha_k)$ 尽可能减小. 这要求:
  - $\alpha_k$ 应该使得 $f$ 充分下降
  - 不应在寻找 $\alpha_k$ 上花费过多的计算量
- 一个自然的想法是寻找 $\alpha_k$ 使得

$$\alpha_k = \operatorname{argmin}_{\alpha > 0} \phi(\alpha),$$

即 $\alpha_k$ 为最佳步长. 这种线搜索算法被称为**精确线搜索算法**

- 选取 $\alpha_k$ 通常需要很大计算量,在实际应用中较少使用

## $\alpha_k$ 的选取:非精确线搜索算法

- 不要求 $\alpha_k$  是 $\phi(\alpha)$  的最小值点, 仅要求 $\phi(\alpha_k)$  满足某些不等式. 这种线搜索方法被称为**非精确线搜索算法**.
- 选取 $\alpha_k$  需要满足的要求被称为**线搜索准则**
- 线搜索准则的合适与否直接决定了算法的收敛性, 若选取**不合适的线搜索准则**将会导致算法无法收敛
- 例如, 若只要求选取的步长满足迭代点处函数值单调下降, 则函数值 $f(x^k)$  的下降量可能不够充分, 导致算法无法收敛到极小值点

## 例子:不合适的线搜索准则导致无法收敛

考虑一维无约束优化问题

$$\min_x f(x) = x^2,$$

迭代初始点  $x^0 = 1$ . 由于问题是一维的, 下降方向只有  $\{-1, +1\}$  两种. 我们选取  $d^k = -\text{sign}(x^k)$ , 且只要求选取的步长满足迭代点处函数值单调下降, 即  $f(x^k + \alpha_k d^k) < f(x^k)$ . 考虑选取如下两种步长:

$$\alpha_{k,1} = \frac{1}{3^{k+1}}, \quad \alpha_{k,2} = 1 + \frac{2}{3^{k+1}},$$

通过简单计算可以得到

$$x_1^k = \frac{1}{2} \left( 1 + \frac{1}{3^k} \right), \quad x_2^k = \frac{(-1)^k}{2} \left( 1 + \frac{1}{3^k} \right).$$

显然, 序列  $\{f(x_1^k)\}$  和序列  $\{f(x_2^k)\}$  均单调下降, 但序列  $\{x_1^k\}$  收敛的点不是极小值点, 序列  $\{x_2^k\}$  则在原点左右振荡, 不存在极限

# Armijo 准则

## 定义 (Armijo 准则)

设  $d^k$  是点  $x^k$  处的下降方向, 若

$$f(x^k + \alpha d^k) \leq f(x^k) + c_1 \alpha \nabla f(x^k)^T d^k,$$

则称步长  $\alpha$  满足 **Armijo 准则**, 其中  $c_1 \in (0, 1)$  是一个常数.




Figure: Armijo 准则

## Armijo 准则:评注

- 引入Armijo 准则的目的是保证每一步迭代充分下降
- Armijo 准则有直观的几何含义, 它指的是点 $(\alpha, \phi(\alpha))$  必须在直线

$$l(\alpha) = \phi(0) + c_1 \alpha \nabla f(x^k)^T d^k$$

的下方, 上图中区间 $[0, \alpha_1]$  中的点均满足Armijo 准则

- 参数 $c_1$  通常选为一个很小的正数, 例如 $c_1 = 10^{-3}$ , Armijo 准则非常容易得到满足
- Armijo 准则需要配合其他准则以保证迭代的收敛性, 因为 $\alpha = 0$  显然满足Armijo 准则, 此时迭代序列中的点固定不变

## 回退法:以Armijo准则为例

- 给定初值 $\hat{\alpha}$ , 回退法通过不断以指数方式缩小试探步长, 找到第一个满足Armijo 准则的点
- 回退法选取

$$\alpha_k = \gamma^{j_0} \hat{\alpha},$$

其中

$$j_0 = \min\{j = 0, 1, \dots \mid f(x^k + \gamma^j \hat{\alpha} d^k) \leq f(x^k) + c_1 \gamma^j \hat{\alpha} \nabla f(x^k)^T d^k\},$$

参数 $\gamma \in (0, 1)$  为一个给定的实数

---

### Algorithm 1 线搜索回退法

---

- 1: 选择初始步长 $\hat{\alpha}$ , 参数 $\gamma, c \in (0, 1)$ . 初始化 $\alpha \leftarrow \hat{\alpha}$ .
- 2: **while**  $f(x^k + \alpha d^k) > f(x^k) + c\alpha \nabla f(x^k)^T d^k$  **do**
- 3:   令 $\alpha \leftarrow \gamma\alpha$ .
- 4: **end while**
- 5: 输出 $\alpha_k = \alpha$ .



## 回退法:以Armijo准则为例

- 该算法被称为回退法是因为 $\alpha$ 的试验值是由大至小的,它可以确保输出的 $\alpha_k$ 能尽量地大
- 算法1不会无限进行下去,因为 $d^k$ 是一个下降方向,当 $\alpha$ 充分小时,Armijo 准则总是成立的
- 实际应用中我们通常也会给 $\alpha$  设置一个下界,防止步长过小

# Goldstein 准则

- 为了克服Armijo 准则的缺陷, 我们需要引入其他准则来保证每一步的 $\alpha^k$  不会太小
- Armijo准则只要求点 $(\alpha, \phi(\alpha))$  必须处在某直线下方, 我们也可使用相同的形式使得该点必须处在另一条直线的上方. 这就是Armijo-Goldstein 准则, 简称Goldstein 准则

## 定义 (Goldstein 准则)

设 $d^k$  是点 $x^k$  处的下降方向, 若

$$f(x^k + \alpha d^k) \leq f(x^k) + c\alpha \nabla f(x^k)^T d^k, \quad (1a)$$

$$f(x^k + \alpha d^k) \geq f(x^k) + (1 - c)\alpha \nabla f(x^k)^T d^k, \quad (1b)$$

则称步长 $\alpha$  满足**Goldstein 准则**, 其中 $c \in (0, \frac{1}{2})$ .

# Goldstein 准则

Goldstein 准则有直观的几何含义, 它指的是点  $(\alpha, \phi(\alpha))$  必须在两条直线

$$l_1(\alpha) = \phi(0) + c\alpha \nabla f(x^k)^T d^k,$$

$$l_2(\alpha) = \phi(0) + (1 - c)\alpha \nabla f(x^k)^T d^k$$

之间. 区间  $[\alpha_1, \alpha_2]$  中的点均满足 Goldstein 准则. 同时我们也注意到 Goldstein 准则确实去掉了过小的  $\alpha$ .




Figure: Goldstein 准则

# Wolfe 准则

- Goldstein 准则能够使得函数值充分下降,但是它可能避开了最优的函数值. 上页图中的一维函数 $\phi(\alpha)$ 的最小值点并不在满足Goldstein 准则的区间 $[\alpha_1, \alpha_2]$  中
- 在Wolfe 准则中, 第一个不等式即是Armijo 准则, 而第二个不等式则是Wolfe 准则的本质要求

## 定义 (Wolfe 准则)

设 $d^k$  是点 $x^k$  处的下降方向, 若

$$f(x^k + \alpha d^k) \leq f(x^k) + c_1 \alpha \nabla f(x^k)^T d^k, \quad (2a)$$

$$\nabla f(x^k + \alpha d^k)^T d^k \geq c_2 \nabla f(x^k)^T d^k, \quad (2b)$$

则称步长 $\alpha$  满足 **Wolfe** 准则, 其中 $c_1, c_2 \in (0, 1)$  为给定的常数且 $c_1 < c_2$ .

# Wolfe 准则

- $\nabla f(x^k + \alpha d^k)^T d^k$  恰好就是  $\phi(\alpha)$  的导数, Wolfe 准则实际要求  $\phi(\alpha)$  在点  $\alpha$  处切线的斜率不能小于  $\phi'(0)$  的  $c_2$  倍
- $\phi(\alpha)$  的极小值点  $\alpha^*$  处有  $\phi'(\alpha^*) = \nabla f(x^k + \alpha^* d^k)^T d^k = 0$ , 因此  $\alpha^*$  永远满足条件二. 而选择较小的  $c_1$  可使得  $\alpha^*$  同时满足条件一, 即 Wolfe 准则在绝大多数情况下会包含线搜索子问题的精确解




Figure: Wolfe 准则

# 非单调线搜索准则

## 定义 (Grippo)

设 $d^k$  是点 $x^k$  处的下降方向,  $M > 0$  为给定的正整数. 以下不等式可作为一种线搜索准则:

$$f(x^k + \alpha d^k) \leq \max_{0 \leq j \leq \min\{k, M\}} f(x^{k-j}) + c_1 \alpha \nabla f(x^k)^T d^k,$$

其中 $c_1 \in (0, 1)$  为给定的常数.

- 该准则和Armijo 准则非常相似, 区别在于Armijo 准则要求下一次迭代的函数值 $f(x^{k+1})$  相对于本次迭代的函数值 $f(x^k)$  有充分下降, 而该准则只需要下一步函数值相比前面至多 $M$  步以内迭代的函数值有下降就可以了
- 这一准则的要求比Armijo 准则更宽, 它也不要求 $f(x^k)$  的单调性

# 非单调线搜索准则

另一种非单调线搜索准则的定义更加宽泛.

## 定义 (Zhang, Hager)

设 $d^k$  是点 $x^k$  处的下降方向,  $M > 0$  为给定的正整数. 以下不等式可作为一种线搜索准则:

$$f(x^k + \alpha d^k) \leq C^k + c_1 \alpha \nabla f(x^k)^T d^k,$$

其中 $C^k$  满足递推式 $C^0 = f(x^0)$ ,  $C^{k+1} = \frac{1}{Q^{k+1}}(\eta Q^k C^k + f(x^{k+1}))$ , 序列 $\{Q^k\}$  满足 $Q^0 = 1$ ,  $Q^{k+1} = \eta Q^k + 1$ , 参数 $\eta, c_1 \in (0, 1)$ .

- 变量 $C^k$  实际上是本次搜索准则的参照函数值, 即充分下降性质的起始标准
- 下一步的标准 $C^{k+1}$  则是函数值 $f(x^{k+1})$  和 $C^k$  的凸组合, 并非仅仅依赖于 $f(x^{k+1})$ , 而凸组合的两个系数由参数 $\eta$  决定
- 当 $\eta = 0$  时, 此准则就是Armijo 准则

# 回退法的优缺点

- 只要修改一下算法的终止条件,回退法就可以被用在其他线搜索准则之上,它是最常用的线搜索算法之一.
- 然而,回退法的缺点也很明显:
  - ❶ 它无法保证找到满足Wolfe 准则的步长,即条件二不一定成立,但对一些优化算法而言,找到满足Wolfe 准则的步长是十分必要的
  - ❷ 回退法以指数的方式缩小步长,因此对初值 $\hat{\alpha}$  和参数 $\gamma$  的选取比较敏感,当 $\gamma$  过大时每一步试探步长改变量很小,此时回退法效率比较低,当 $\gamma$  过小时回退法过于激进,导致最终找到的步长太小,错过了选取大步长的机会



# 基于多项式插值的线搜索算法

- 设初始步长 $\hat{\alpha}_0$ 已给定, 如果经过验证,  $\hat{\alpha}_0$  不满足Armijo 准则, 下一步就需要减小试探步长
- 基于 $\phi(0), \phi'(0), \phi(\hat{\alpha}_0)$  这三个信息构造一个二次插值函数 $p_2(\alpha)$
- 寻找二次函数 $p_2(\alpha)$  满足

$$p_2(0) = \phi(0), \quad p_2'(0) = \phi'(0), \quad p_2(\hat{\alpha}_0) = \phi(\hat{\alpha}_0).$$

由于二次函数只有三个参数, 以上三个条件可以唯一决定 $p_2(\alpha)$

- $p_2(\alpha)$  的最小值点恰好位于 $(0, \hat{\alpha}_0)$  内
- 取 $p_2(\alpha)$  的最小值点 $\hat{\alpha}_1$  作为下一个试探点, 利用同样的方式不断递归下去直至找到满足Armijo 准则的点
- 基于插值的线搜索算法可以有效减少试探次数, 但仍然不能保证找到的步长满足Wolfe 准则

# 提纲

- 1 线搜索准则
- 2 线搜索算法
- 3 收敛性分析
- 4 梯度下降法
- 5 Barzilar-Borwein 方法
- 6 应用举例

# Zoutendijk定理

## 定理 (Zoutendijk定理)

考虑一般的迭代格式  $x^{k+1} = x^k + \alpha_k d^k$ , 其中  $d^k$  是搜索方向,  $\alpha_k$  是步长, 且在迭代过程中 **Wolfe** 准则满足. 假设目标函数  $f$  下有界、连续可微且梯度  $L$ -利普希茨连续, 即

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|, \quad \forall x, y \in \mathbb{R}^n,$$

那么

$$\sum_{k=0}^{\infty} \cos^2 \theta_k \|\nabla f(x^k)\|^2 < +\infty,$$

其中  $\cos \theta_k$  为负梯度  $-\nabla f(x^k)$  和下降方向  $d^k$  夹角的余弦, 即

$$\cos \theta_k = \frac{-\nabla f(x^k)^T d^k}{\|\nabla f(x^k)\| \|d^k\|}.$$

这个不等式也被称为 **Zoutendijk** 条件.

## Zoutendijk定理的证明

- 由Wolfe准则知 $\nabla f(x^{k+1})^T d^k \geq c_2 f(x^k)^T d^k$ , 故

$$(\nabla f(x^{k+1}) - \nabla f(x^k))^T d^k \geq (c_2 - 1) \nabla f(x^k)^T d^k.$$

- 由柯西不等式和梯度 $L$ -利普希茨连续性质,

$$(\nabla f(x^{k+1}) - \nabla f(x^k))^T d^k \leq \|\nabla f(x^{k+1}) - \nabla f(x^k)\| \|d^k\| \leq \alpha_k L \|d^k\|^2.$$

- 结合上述两式可得

$$\alpha_k \geq \frac{c_2 - 1}{L} \frac{\nabla f(x^k)^T d^k}{\|d^k\|^2}.$$

- 由Wolfe准则的条件一知 $f(x^{k+1}) \leq f(x^k) + c_1 \alpha_k \nabla f(x^k)^T d^k$ , 注意到 $\nabla f(x^k)^T d^k < 0$ , 将上式代入得

$$f(x^{k+1}) \leq f(x^k) + c_1 \frac{c_2 - 1}{L} \frac{(\nabla f(x^k)^T d^k)^2}{\|d^k\|^2}.$$

# Zoutendijk定理的证明

- 根据 $\theta_k$ 的定义, 此不等式可等价表述为

$$f(x^{k+1}) \leq f(x^k) + c_1 \frac{c_2 - 1}{L} \cos^2 \theta_k \|\nabla f(x^k)\|^2.$$

- 再关于 $k$ 求和, 我们有

$$f(x^{k+1}) \leq f(x^0) - c_1 \frac{1 - c_2}{L} \sum_{j=0}^k \cos^2 \theta_j \|\nabla f(x^j)\|^2.$$

- 又因为函数 $f$ 是下有界的, 且由 $0 < c_1 < c_2 < 1$ 可知 $c_1(1 - c_2) > 0$ , 因此当 $k \rightarrow \infty$ 时,

$$\sum_{j=0}^{\infty} \cos^2 \theta_j \|\nabla f(x^j)\|^2 < +\infty.$$

# 线搜索算法的收敛性

Zoutendijk 定理刻画了线搜索准则的性质, 配合下降方向 $d^k$  的选取方式我们可以得到最基本的收敛性.

## 推论 (线搜索算法的收敛性)

对于迭代法 $x^{k+1} = x^k + \alpha_k d^k$ , 设 $\theta_k$  为每一步负梯度 $-\nabla f(x^k)$  与下降方向 $d^k$  的夹角, 并假设对任意的 $k$ , 存在常数 $\gamma > 0$ , 使得

$$\theta_k < \frac{\pi}{2} - \gamma,$$

则在 Zoutendijk 定理成立的条件下, 有

$$\lim_{k \rightarrow \infty} \nabla f(x^k) = 0.$$

# 线搜索算法收敛性的证明

- 假设结论不成立, 即存在子列 $\{k_l\}$  和正常数 $\delta > 0$ , 使得

$$\|\nabla f(x^{k_l})\| \geq \delta, \quad l = 1, 2, \dots.$$

- 根据 $\theta_k$  的假设, 对任意的 $k$ ,

$$\cos \theta_k > \sin \gamma > 0.$$

- 我们仅考虑Zoutendijk条件中第 $k_l$  项的和, 有

$$\begin{aligned} \sum_{k=0}^{\infty} \cos^2 \theta_k \|\nabla f(x^k)\|^2 &\geq \sum_{l=1}^{\infty} \cos^2 \theta_{k_l} \|\nabla f(x^{k_l})\|^2 \\ &\geq \sum_{l=1}^{\infty} (\sin^2 \gamma) \cdot \delta^2 \rightarrow +\infty, \end{aligned}$$

- 这显然和Zoutendijk定理矛盾. 因此必有

$$\lim_{k \rightarrow \infty} \nabla f(x^k) = 0.$$

## 收敛性分析:评注

- 线搜索算法收敛性建立在Zoutendijk条件之上, 它的本质要求是 $\theta_k < \frac{\pi}{2} - \gamma$ , 即每一步的下降方向 $d^k$ 和负梯度方向不能趋于正交.
- 几何直观: 当下降方向 $d^k$ 和梯度正交时, 根据泰勒展开的一阶近似, 目标函数值 $f(x^k)$ 几乎不发生改变. 因此我们要求 $d^k$ 与梯度正交方向夹角有一致的下界.
- 不涉及算法收敛速度的分析, 因为算法收敛速度极大地取决于 $d^k$ 的选取.