

最优化计算方法（简化版）

参考答案

丁思哲 邓展望 李天佑 陈铖 谢中林 俞建江
 刘浩洋 文再文

版本： v1.01 （更新于 2022.05.09）

教材链接： <https://bicmr.pku.edu.cn/~wenzw/optbook.html>

目录

第一章 最优化简介	1
第二章 基础知识	5
第三章 典型优化问题	15
第四章 最优性理论	25
第五章 无约束优化算法	41
第六章 约束优化算法	49
第七章 复合优化算法	65
更新历史	81
致谢	83

第一章 最优化简介

1.1 考虑稀疏优化问题，我们已经直观地讨论了在 ℓ_0 , ℓ_1 , ℓ_2 三种范数下问题的解的可能形式. 针对一般的 ℓ_p “范数”:

$$\|x\|_p \stackrel{\text{def}}{=} \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}, \quad 0 < p < 2,$$


我们考虑优化问题:

$$\begin{aligned} \min \quad & \|x\|_p, \\ \text{s.t.} \quad & Ax = b. \end{aligned}$$

试着用几何直观的方式 (类似于图 1.2) 来说明当 $p \in (0, 2)$ 取何值时, 该优化问题的解可能具有稀疏性.

解 (丁思哲). $Ax = b$ 表示空间中的直线, $\|x\|_p (0 < p < 2)$ 引导的 $\{x \mid \|x\|_p \leq C\}$ 表示空间中的 ℓ_p 范数球. 优化问题实际是找到最小的 C , 使得范数球与 $Ax = b$ 相交. 在 \mathbb{R}^2 空间中, 不同 p 的范数球情形如图 1.1 所示.

- 当 $p \in (0, 1)$ 时, ℓ_p 范数球是内凸的, 因此最小的 C 对应的范数球与直线的交点一般都是坐标轴上的顶点, 因此 ℓ_p 范数的解具有稀疏性;
- 当 $p = 1$ 时, ℓ_p 范数球呈现“正方形”, 且正方形的顶点恰在坐标轴上, 因此在一定条件下 (例如直线不与正方形的某边平行) 最小的 C 对应的范数球与直线的交点一般也是坐标轴上的顶点, 因此 ℓ_1 范数的解也具有稀疏性;
- 当 $p \in (1, 2)$ 时, ℓ_p 范数球是外凸的, 此时最小的 C 对应的范数球与直线的交点不一定在坐标轴上, 那么 ℓ_p 范数的解一般不具有稀疏性.

图 1.1 ℓ_p 范数优化问题的求解

□

- 1.2** 给定一个函数 $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$ 及其一个局部最优点 x^* , 则该点沿任何方向 $d \in \mathbb{R}^n$ 也是局部最优的, 即 0 为函数 $\phi(\alpha) \stackrel{\text{def}}{=} f(x^* + \alpha d)$ 的一个局部最优解. 反之, 如果 x^* 沿任何方向 $d \in \mathbb{R}^n$ 都是局部最优解, 则 x^* 是否为 $f(x)$ 的一个局部最优解? 若是, 请给出证明; 若不是, 请给出反例.

解 (俞建江). x^* 不一定是 $f(x)$ 的局部最优解. 反例: 如用极坐标表示 f

$$f(r, \theta) = \begin{cases} r \sin(\frac{r}{\theta}), & \theta \in (0, 2\pi), \\ 0, & \theta = 0. \end{cases}$$

在任一方向上, $r = 0$ 都是局部最优解, 但 $x = 0$ 的任一邻域内都存在 x' 使得 $f(x') < 0$. 造成这一现象的原因之一是, 某些函数在局部具有一定的振荡特性. □

- 1.3** 考虑函数 $f(x) = x_1^2 + x_2^2$, $x = (x_1, x_2) \in \mathbb{R}^2$, 以及迭代点列 $x^k = (1 + \frac{1}{2^k})(\cos k, \sin k)^T, k = 1, 2, \dots$, 请说明
- (a) $\{f(x^{k+1})\}$ 是否收敛? 若收敛, 给出 Q-收敛速度;
 - (b) $\{x^{k+1}\}$ 是否收敛? 若收敛, 给出 Q-收敛速度.

解 (俞建江).

(a) 该点列收敛, 且 $f(x^{k+1}) = (1 + \frac{1}{2^k})^2$, $k \rightarrow \infty$ 时 $f \rightarrow 1$.

因为

$$\lim_{k \rightarrow \infty} \frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|} = \lim_{k \rightarrow \infty} \frac{(1 + \frac{1}{2^{k+1}})^2 - 1}{(1 + \frac{1}{2^k})^2 - 1} = \frac{1}{2},$$

所以该点列还是 Q-线性收敛的.

(b) 该点列不收敛. 因为显然 $\cos k$ 和 $\sin k$ 都不收敛, 但 $1 + \frac{1}{2^k}$ 收敛到 1. \square

第二章 基础知识

2.1 证明: 矩阵 A 的 2 范数等于其最大奇异值, 即

$$\sigma_1(A) = \max_{\|x\|_2=1} \|Ax\|_2.$$

解 (俞建江, 丁思哲). 由矩阵 2 范数和向量 2 范数的定义,

$$\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|_2 = \max_{\|x\|_2=1} [(Ax)^T Ax]^{\frac{1}{2}} = \max_{\|x\|_2=1} [x^T (A^T A) x]^{\frac{1}{2}}.$$

注意到 $A^T A$ 是实对称且半正定的, 不妨设其 n 个非负实特征值为

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n \geq 0.$$

实对称矩阵 n 不同特征值对应的特征向量必正交, 因此不妨设它们对应的正交规范特征向量为 v_1, v_2, \dots, v_n , 则对任一满足 $\|x\|_2 = 1$ 的向量 $x \in \mathbb{R}^n$ 成立线性组合结构

$$x = \sum_{i=1}^n \alpha_i v_i, \quad \sum_{i=1}^n \alpha_i^2 = 1,$$

其中 $\alpha_i \in \mathbb{R}$ 是系数.

将上式代入定义, 得

$$x^T A^T A x = \sum_{i=1}^n \lambda_i \alpha_i^2 \leq \lambda_1,$$

也即 $\|A\|_2 \leq \lambda_1$.

另一方面, 若取 $x = v_1$, 则有

$$x^T A^T A x = v_1^T A^T A v_1 = \lambda_1,$$

故 $\|A\|_2 \geq \lambda_1$.

综上,

$$\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|_2 = \sqrt{\lambda_1} = \sqrt{\lambda_{\max}(A^T A)} = \sigma_1(A). \quad \square$$

2.2 证明如下有关矩阵范数的不等式:

$$(a) \|AB\|_F \leq \|A\|_2 \|B\|_F,$$

$$(b) |\langle A, B \rangle| \leq \|A\|_2 \|B\|_*.$$

解 (俞建江).

(a) 利用 F 范数的定义,

$$\begin{aligned} \|AB\|_F^2 &= \langle AB, AB \rangle \\ &= \text{Tr}(B^T A^T AB) \\ &= \text{Tr}(BB^T A^T A). \end{aligned}$$

$A^T A$ 是对称半正定阵, 它可以被正交对角化. 因此存在正交矩阵 T , 使得

$$T^T A^T A T = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n).$$

其中 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$. 利用 T , 对 F 范数的定义可作

$$\begin{aligned} \text{Tr}(BB^T A^T A) &= \text{Tr}(T^T BB^T T T^T A^T A T) \\ &\leq \lambda_1 \text{Tr}(T^T BB^T T) \\ &= \lambda_1 \text{Tr}(BB^T) \\ &= \|A\|_2^2 \|B\|_F^2, \end{aligned}$$

因此 $\|AB\|_F \leq \|A\|_2 \|B\|_F$ 成立.

(b) 设 $A, B \in \mathbb{R}^{m \times n}$, 不妨设 $m \geq n$. B 存在 SVD 分解

$$B = U_B \Sigma_B V_B^T, \quad U_B \in \mathbb{R}^{m \times m}, V_B \in \mathbb{R}^{n \times n},$$

其中 U_B, V_B 都是正交矩阵, Σ_B 是对角矩阵.

利用矩阵内积的定义,

$$\begin{aligned} |\langle A, B \rangle| &= \text{Tr}(B^T A) \\ &= \text{Tr}(V_B \Sigma_B U_B^T A) \\ &= \text{Tr}(\Sigma_B U_B^T A V_B), \end{aligned}$$

其中记 $\Sigma_B = \text{diag}(\tilde{b}_1, \tilde{b}_2, \dots, \tilde{b}_n)$.

规定 $\tilde{A} = U_B^T A V_B = (\tilde{a}_{ij})_{m \times n}$, 对 \tilde{A} 的每个对角元 \tilde{a}_{ii} , 成立

$$\begin{aligned} |\tilde{a}_{ii}| &\leq \sqrt{\tilde{a}_{1i}^2 + \tilde{a}_{2i}^2 + \dots + \tilde{a}_{mi}^2} \\ &= \frac{\|\tilde{A}e_i\|_2}{\|e_i\|_2} \\ &= \|\tilde{A}e_i\|_2 \\ &\leq \|A\|_2, \end{aligned}$$

因此有

$$\begin{aligned} \langle A, B \rangle &= \text{Tr}(\Sigma_B \tilde{A}) \\ &= \sum_{i=1}^n \tilde{b}_i \tilde{a}_{ii} \\ &\leq \|A\|_2 \sum_{i=1}^n \tilde{b}_i \\ &= \|A\|_2 \|B\|_*. \end{aligned}$$

□

2.3 假设 A 和 B 均为半正定矩阵, 求证: $\langle A, B \rangle \geq 0$. 提示: 利用对称矩阵的特征值分解.

解 (俞建江). 由 A 是半正定矩阵, 对 A 进行谱分解

$$A = T^T \Sigma_A T,$$

其中 T 是正交矩阵, Σ_A 是对角线元素全非负的对角矩阵. 则

$$\begin{aligned} \langle A, B \rangle &= \text{Tr}(T^T \Sigma_A T B) \\ &= \text{Tr}(\Sigma_A T B T^T). \end{aligned}$$

显然 $T B T^T$ 也是半正定矩阵, 其对角线元素都非负, 因此

$$\langle A, B \rangle = \text{Tr}(\Sigma_A T B T^T) \geq 0.$$

□

2.4 计算下列矩阵变量函数的导数.

- (a) $f(X) = a^T X b$, 这里 $X \in \mathbb{R}^{m \times n}$, $a \in \mathbb{R}^m, b \in \mathbb{R}^n$ 为给定的向量;
- (b) $f(X) = \text{Tr}(X^T A X)$, 其中 $X \in \mathbb{R}^{m \times n}$ 是长方形矩阵, A 是方阵 (但不一定对称);

解 (俞建江, 丁思哲).

(a) 对任意方向的 $V \in \mathbb{R}^{m \times n}$ 和 $t \in \mathbb{R}$, 有

$$\begin{aligned} & \lim_{t \rightarrow 0} \frac{f(X + tV) - f(X)}{t} \\ &= a^T V b = \text{Tr}(a^T V b) = \text{Tr}(b a^T V) = \langle a b^T, V \rangle, \end{aligned}$$

因此 $\nabla f(X) = a b^T$.

(b) 对任意方向的 $V \in \mathbb{R}^{m \times n}$ 和 $t \in \mathbb{R}$, 有

$$\begin{aligned} f(X + tV) - f(X) &= t \text{Tr}(V^T A X + X^T A V) + \mathcal{O}(t^2) \\ &= t (\langle A X, V \rangle + \langle A^T X, V \rangle) + \mathcal{O}(t^2), \end{aligned}$$

因此 $\nabla f(X) = (A + A^T)X$.

(c) 对任意方向的 $V \in \mathbb{R}^{n \times n}$ 和 $t \in \mathbb{R}$,

$$\begin{aligned} f(X + tV) - f(X) &= \ln(\det(X + tV)) - \ln(\det(X)) \\ &= \ln(\det(I + tV X^{-1})). \end{aligned}$$

设 $V X^{-1}$ 的所有特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$ (可能有复数). 则 $I + tV X^{-1}$ 的所有特征值为 $1 + t\lambda_1, 1 + t\lambda_2, \dots, 1 + t\lambda_n$. 利用

$$\det(I + tV X^{-1}) = \prod_{i=1}^n (1 + t\lambda_i)$$

的结论, 成立

$$\begin{aligned} f(X + tV) - f(X) &= \ln \prod_{i=1}^n (1 + t\lambda_i) \\ &= t \sum_{i=1}^n \lambda_i + \mathcal{O}(t^2) \\ &= t \text{Tr}(V X^{-1}) + \mathcal{O}(t^2) \\ &= t \langle X^{-T}, V \rangle + \mathcal{O}(t^2), \end{aligned}$$

即最终成立 $\nabla f(X) = X^{-T}$. □

2.5 考虑二次不等式

$$x^T A x + b^T x + c \leq 0,$$

其中 A 为 n 阶对称矩阵, 设 C 为上述不等式的解集.

- (a) 证明：当 A 正定时， C 为凸集；
- (b) 设 C' 是 C 和超平面 $g^T x + h = 0$ 的交集 ($g \neq 0$)，若存在 $\lambda \in \mathbb{R}$ ，使得 $A + \lambda g g^T$ 半正定，证明： C' 为凸集。

解 (俞建江)。

- (a) 记 $f(x) = x^T A x + b^T x + c$ ，则 $\nabla^2 f(x) = 2A \succ 0$ ，知 $f(x)$ 是严格凸函数。对 $\forall x_1, x_2 \in C$ 以及 $t \in (0, 1)$ ，

$$f(tx_1 + (1-t)x_2) \leq tf(x_1) + (1-t)f(x_2) \leq 0,$$

因此 $tx_1 + (1-t)x_2 \in C$ ，知 C 是凸集。

- (b) 对 $\forall x_1, x_2 \in C'$ 以及 $t \in (0, 1)$ ，记 $x_3 = tx_1 + (1-t)x_2$ 。显然 x_3 在超平面 $g^T x + h = 0$ 上，只需再证明 $x_3 \in C$ 。容易验证：

$$\begin{aligned} f(x_3) &= tf(x_1) + (1-t)f(x_2) - t(1-t)(x_2 - x_1)^T A(x_2 - x_1) \\ &= tf(x_1) + (1-t)f(x_2) + \lambda t(1-t)(x_2 - x_1)^T g g^T (x_2 - x_1) \\ &\quad - t(1-t)(x_2 - x_1)^T (A + \lambda g g^T)(x_2 - x_1), \end{aligned}$$

由于 $(x_2 - x_1)^T g = 0$ ，因此 $(x_2 - x_1)^T g g^T (x_2 - x_1) = 0$ 。那么，再由 $A + \lambda g g^T$ 半正定，得 $f(x_3) \leq 0$ 。故 $x_3 \in C$ ，命题得证。□

2.6 利用凸函数二阶条件证明如下结论：

- (a) ln-sum-exp 函数： $f(x) = \ln \sum_{k=1}^n \exp x_k$ 是凸函数；
- (b) 几何平均： $f(x) = \left(\prod_{k=1}^n x_k \right)^{1/n}$ ($x \in \mathbb{R}_{++}^n$) 是凹函数；
- (c) 设 $f(x) = \left(\sum_{i=1}^n x_i^p \right)^{1/p}$ ，其中 $p \in (0, 1)$ ，定义域为 $x > 0$ ，则 $f(x)$ 是凹函数。

解 (俞建江)。

(a) 求海瑟矩阵, 为了方便记 $S = \sum_{k=1}^n \exp x_k$ 。则

$$\nabla^2 f = \frac{1}{S^2} \cdot \begin{bmatrix} e^{x_1}(S - e^{x_1}) & -e^{x_1}e^{x_2} & \cdots & -e^{x_1}e^{x_n} \\ -e^{x_2}e^{x_1} & e^{x_2}(S - e^{x_2}) & \cdots & -e^{x_2}e^{x_n} \\ \vdots & \vdots & \ddots & \vdots \\ -e^{x_n}e^{x_1} & -e^{x_n}e^{x_2} & \cdots & e^{x_n}(S - e^{x_n}) \end{bmatrix}.$$

现在只需证明 $\nabla^2 f$ 半正定.

对 $\forall y = (y_1, y_2, \dots, y_n)^T \in \mathbb{R}^n (y \neq 0)$, 成立

$$y^T \nabla^2 f y = \frac{1}{S^2} \left[\sum_{k=1}^n y_k^2 e^{x_k} \sum_{k=1}^n e^{x_k} - \left(\sum_{k=1}^n y_k e^{x_k} \right)^2 \right],$$

利用柯西不等式可知 $y^T \nabla^2 f y \geq 0$. 因此 $\nabla^2 f \succeq 0$.

(b) 求海瑟矩阵, 得

$$\begin{aligned} \nabla f(x) &= \frac{f}{n} \left(\frac{1}{x_1}, \frac{1}{x_2}, \dots, \frac{1}{x_n} \right)^T, \\ \nabla^2 f(x) &= -\frac{f}{n^2} \begin{bmatrix} \frac{n-1}{x_1^2} & -\frac{1}{x_1 x_2} & \cdots & -\frac{1}{x_1 x_n} \\ -\frac{1}{x_2 x_1} & \frac{n-1}{x_2^2} & \cdots & -\frac{1}{x_2 x_n} \\ \vdots & \vdots & \ddots & \vdots \\ -\frac{1}{x_n x_1} & -\frac{1}{x_n x_2} & \cdots & \frac{n-1}{x_n^2} \end{bmatrix}. \end{aligned}$$

设 $J(x) = \text{Diag} \left(\frac{1}{x_1}, \dots, \frac{1}{x_n} \right)$, 注意到 $\nabla^2 f(x) =$

$$-\frac{f}{n^2} J(x) \begin{bmatrix} n-1 & -1 & \cdots & -1 \\ -1 & n-1 & \cdots & -1 \\ \vdots & \vdots & \ddots & \vdots \\ -1 & -1 & \cdots & n-1 \end{bmatrix} J(x).$$

容易验证上式中间的矩阵是个实对称矩阵且其特征值为 n (该特征值是 $n-1$ 重的) 和 0 , 是半正定矩阵, 因此 $\nabla^2 f(x)$ 是半负定矩阵.

(c) 求海瑟矩阵, 设 $J(x) = \text{Diag}\left(\frac{1}{x_1}, \dots, \frac{1}{x_n}\right)$, 得

$$\begin{aligned}\nabla f(x) &= \left(\left(\frac{f}{x_1}\right)^{1-p}, \left(\frac{f}{x_2}\right)^{1-p}, \dots, \left(\frac{f}{x_n}\right)^{1-p} \right)^T, \\ \nabla^2 f(x) &= -\frac{1-p}{f} J(x) A(x) J(x),\end{aligned}$$

其中

$$A(x) = \begin{bmatrix} (f^p - x_1^p)x_1^p & -x_1^p x_2^p & \cdots & -x_1^p x_n^p \\ -x_2^p x_1^p & (f^p - x_2^p)x_2^p & \cdots & -x_2^p x_n^p \\ \vdots & \vdots & \ddots & \vdots \\ -x_n^p x_1^p & -x_n^p x_2^p & \cdots & (f^p - x_n^p)x_n^p \end{bmatrix}.$$

只需证明 $A(x)$ 半正定. 对 $\forall y \in \mathbb{R}^n$ 且 $y \neq 0$,

$$\begin{aligned}y^T A(x) y &= \left(\sum_{k=1}^n y_k^2 x_k^p \right) f^p - \left(\sum_{k=1}^n y_k x_k^p \right)^2 \\ &= \left(\sum_{k=1}^n y_k^2 x_k^p \right) \left(\sum_{k=1}^n x_k^p \right) - \left(\sum_{k=1}^n y_k x_k^p \right)^2,\end{aligned}$$

并由柯西不等式得 $y^T A(x) y \geq 0$. 因此 $A(x) \succeq 0$, $\nabla^2 f(x) \preceq 0$. \square

2.7 证明定理 2.12.

解 (俞建江). 先证充分性. 对 $\forall x_1, x_2 \in \text{dom } f, \forall t \in (0, 1)$, 记 $x_3 = tx_1 + (1-t)x_2$. 显然 $(x_1, f(x_1)), (x_2, f(x_2)) \in \text{epi } f$, 由题设 $\text{epi } f$ 是凸集, 得

$$(x_3, tf(x_1) + (1-t)f(x_2)) \in \text{epi } f,$$

即

$$f(x_3) \leq tf(x_1) + (1-t)f(x_2),$$

因此 $f(x)$ 是凸函数.

再证明必要性. 对 $\forall (x_1, t_1), (x_2, t_2) \in \text{epi } f, \forall t \in (0, 1)$, 记 $(x_3, t_3) = t(x_1, t_1) + (1-t)(x_2, t_2)$. 由 $f(x)$ 凸函数性质:

$$f(x_3) \leq tf(x_1) + (1-t)f(x_2) \leq tt_1 + (1-t)t_2 = t_3$$

得到 $(x_3, t_3) \in \text{epi } f$. 故 $\text{epi } f$ 是凸集. \square

2.8 求下列函数的共轭函数:

- (a) 负熵: $\sum_{i=1}^n x_i \ln x_i$;
- (b) 矩阵对数: $f(x) = -\ln \det(X)$;
- (c) 最大值函数: $f(x) = \max_i x_i$;
- (d) 二次锥上的对数函数: $f(x, t) = -\ln(t^2 - x^T x)$, 注意这里 f 的自变量是 (x, t) .

解 (丁思哲).

- (a) 若补充定义 $\lim_{x \rightarrow 0} x \ln x = 0$, $\mathbf{dom} f = \{x \mid x \geq 0\}$.
由共轭函数的定义, 取 $y \in \mathbb{R}^n$, 且

$$\begin{aligned} f^*(y) &= \sup_{x \in \mathbf{dom} f} \{y^T x - f(x)\} \\ &= \sup_{x \in \mathbf{dom} f} \left\{ \sum_{i=1}^n y_i x_i - \sum_{i=1}^n x_i \ln x_i \right\} \\ &= \sum_{i=1}^n e^{y_i - 1}. \end{aligned}$$

- (b) 显然 $\mathbf{dom} f = \{X \in \mathbb{R}^{n \times n} \mid \det(X) > 0\}$. 我们先形式化地引入 $Y \in \mathbb{R}^{n \times n}$, 假设下述运算都是有意义的.

共轭函数

$$\begin{aligned} f^*(Y) &= \sup_{X \in \mathbf{dom} f} \{\mathrm{Tr}(Y^T X) - f(X)\} \\ &= \sup_{X \in \mathbf{dom} f} \{\mathrm{Tr}(Y^T X) + \ln \det(X)\}, \end{aligned}$$

因为

$$\begin{aligned} d(\mathrm{Tr}(Y^T X)) &= \mathrm{Tr}(d(Y^T X)) = \mathrm{Tr}(Y^T dX), \\ d(\ln \det(X)) &= \det(X)^{-1} d(\det(X)) = \mathrm{Tr}(X^{-1} dX), \end{aligned}$$

因此

$$\frac{d(\mathrm{Tr}(Y^T X) + \ln \det(X))}{dX} = Y + (X^T)^{-1}.$$

故取 $X = -(Y^T)^{-1}$ 时, 满足

$$f^*(Y) = -n - \ln \det(-Y),$$

其中 Y 的定义域是 $\{Y \in \mathbb{R}^{n \times n} \mid \det(-Y) > 0\}$.

- (c) 分情况讨论. 若 $\|y\|_1 \leq 1$ 且 $y \geq 0$, 则 y 与 x 内积时不会改变 x 分量的符号, 且一定成立

$$y^T x \leq \max_i x_i,$$

故此时 $f^*(y) = 0$.

若不然, 则或有 $\|y\|_1 > 1$. 不妨设 $j = \arg \max_i x_i$ 且 $y_j = 1 + \delta$ ($\delta > 0$ 且其他坐标取 0), 那么

$$\begin{aligned} f^*(y) &= \sup_{x \in \mathbb{R}^n} \{y^T x - x_j\} \\ &= \sup_{x_j \in \mathbb{R}} \{\delta x_j\} \\ &\rightarrow \infty. \end{aligned}$$

又或存在 i 使得 $y_i < 0$, 类似可证 $f^*(y)$ 不存在.

综上, $f^*(y) = 0$, 定义域是 $\{y \in \mathbb{R}^n \mid y \geq 0, \|y\|_1 \leq 1\}$.

- (d) 考虑取 $y \in \mathbb{R}^n$, $q \in \mathbb{R}$, 且

$$f^*(y, q) = \sup_{x, t} \{y^T x + qt + \ln(t^2 - x^T x)\},$$

分别对

$$g(x, y, t, q) = y^T x + qt + \ln(t^2 - x^T x)$$

中的变量 x, t 求其稳定点, 得等式组

$$x = \frac{1}{2} (t^2 - x^T x) y, \quad (2.1)$$

$$t = -\frac{1}{2} (t^2 - x^T x) q. \quad (2.2)$$

利用 (2.1) 和 (2.2) 即可注意到 $x = -\frac{t}{q}y$. 此式代入 g 可以消去 x , 代入等式 (2.2) 可以用 y 和 q 表示 t . 此时

$$g(y, t, q) = -\frac{t}{q} y^T y + qt + \ln \left(t^2 - \frac{t^2}{q^2} y^T y \right),$$

并且 $t = \frac{-2q}{q^2 - y^T y}$. 将 t 的表达式代入 g 消去 t , 得到

$$f^*(y, q) = -2 + \ln \left(\frac{4}{q^2 - y^T y} \right),$$

定义域为 $\{(y, q) \mid q^2 - y^T y > 0\}$. □

2.9 求下列函数的一个次梯度:

$$f(x) = \|Ax - b\|_2 + \|x\|_2.$$

解 (俞建江). 一个次梯度为:

$$g(x) = \begin{cases} \frac{A^T(Ax - b)}{\|Ax - b\|_2} + \frac{x}{\|x\|_2}, & Ax - b \neq 0, x \neq 0, \\ \frac{A^T(Ax - b)}{\|Ax - b\|_2}, & Ax - b \neq 0, x = 0, \\ \frac{x}{\|x\|_2}, & Ax - b = 0, x \neq 0, \\ 0, & Ax - b = 0, x = 0. \end{cases}$$

□

2.10 设 $f(x)$ 为 m -强凸函数, 求证: 对于任意的 $x \in \text{int dom } f$,

$$f(x) - \inf_{y \in \text{dom } f} f(y) \leq \frac{1}{2m} \text{dist}^2(0, \partial f(x)),$$

其中 $\text{dist}(z, S)$ 表示点 z 到集合 S 的欧几里得距离.

解 (俞建江). 对 $\forall x, y \in \text{int dom } f$, 由引理 2.2, 对 $\forall g \in \partial f(x)$,

$$f(y) - f(x) \geq g^T(y - x) + \frac{m}{2} \|y - x\|_2^2 \geq -\frac{1}{2m} \|g\|_2^2,$$

后一个不等式在 $y - x = -\frac{g}{m}$ 时取等. 变号后有:

$$f(x) - f(y) \leq \frac{1}{2m} \|g\|_2^2,$$

由于 y, g 均是任取的, 不等式左边取极大, 右边取极小, 成立

$$f(x) - \inf_{y \in \text{dom } f} f(y) \leq \frac{1}{2m} \text{dist}^2(0, \partial f(x)).$$

□

第三章 典型优化问题

3.1 将下面的问题转化为线性规划：给定 $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^n$,

(a) $\min_{x \in \mathbb{R}^n} \|Ax - b\|_1, \quad \text{s.t.} \quad \|x\|_\infty \leq 1;$

(b) $\min_{x \in \mathbb{R}^n} \|x\|_1, \quad \text{s.t.} \quad \|Ax - b\|_\infty \leq 1;$

(c) $\min_{x \in \mathbb{R}^n} \|Ax - b\|_1 + \|x\|_\infty;$

(d) $\min_{x \in \mathbb{R}^n} \sum_{i=1}^m \max\{0, a_i^T x + b_i\}.$

解 (丁思哲). 分别就本题存在的非线性项作如下转化:

- 目标函数中存在 ℓ_1 范数的情形, 例如 $\|x\|_1$, 可以转化为

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \|x\|_1 &= \min_{x_i \in \mathbb{R}} \sum_{i=1}^n |x_i| \\ &\Rightarrow \min_{z_i \in \mathbb{R}_+} \sum_{i=1}^n z_i \quad \text{s.t.} \quad -z_i \leq x_i \leq z_i. \end{aligned}$$

- 目标函数中存在 \max 函数的情形, 例如 $\max\{0, x_i\}$ 的和. 注意到

$$\max\{0, x_i\} = \frac{|x_i| + x_i}{2},$$

就可以转化为目标函数中存在 ℓ_1 范数的情形. 或者也可以引入 $z_i \geq 0$ 并转化为

$$\min_{z_i \in \mathbb{R}_+} \sum_{i=1}^n z_i \quad \text{s.t.} \quad z_i \geq x_i.$$

- 目标函数中存在 ℓ_∞ 范数的情形, 例如 $\|x\|_\infty$. 注意到

$$\begin{aligned}\min_{x \in \mathbb{R}^n} \|x\|_\infty &= \min_{x_i \in \mathbb{R}} \max\{|x_i|\} \\ &\Rightarrow \min_{t \in \mathbb{R}_+} t \quad \text{s.t.} \quad -t\mathbf{1} \leq x \leq t\mathbf{1}.\end{aligned}$$

- 条件中存在 ℓ_∞ 范数的情形. 参考上一项, 例如对 $\|x\|_\infty \leq \alpha$ 变换为

$$-\alpha\mathbf{1} \leq x \leq \alpha\mathbf{1}.$$

根据以上变换的形式, 各小问转化成的线性规划问题分别是:

(a)

$$\begin{aligned}\min_{x \in \mathbb{R}^n, z \in \mathbb{R}_+^m} \quad & \sum_{i=1}^n z_i \\ \text{s.t.} \quad & -z \leq Ax - b \leq z, \\ & -\mathbf{1} \leq x \leq \mathbf{1}.\end{aligned}$$

(b)

$$\begin{aligned}\min_{x \in \mathbb{R}^n, z \in \mathbb{R}_+^m} \quad & \sum_{i=1}^m z_i \\ \text{s.t.} \quad & -z \leq x \leq z, \\ & -\mathbf{1} \leq Ax - b \leq \mathbf{1}.\end{aligned}$$

(c)

$$\begin{aligned}\min_{x \in \mathbb{R}^n, z \in \mathbb{R}_+^m, t \in \mathbb{R}_+} \quad & \sum_{i=1}^m z_i + t \\ \text{s.t.} \quad & -z \leq Ax - b \leq z, \\ & -t\mathbf{1} \leq x \leq t\mathbf{1}.\end{aligned}$$

(d)

$$\begin{aligned}\min_{x \in \mathbb{R}^n, z \in \mathbb{R}_+^m} \quad & \sum_{i=1}^m z_i \\ \text{s.t.} \quad & z \geq Ax + b.\end{aligned}$$

□

3.2 求解下面的线性规划问题: 给定向量 $c \in \mathbb{R}^n$,

$$(a) \min_{x \in \mathbb{R}^n} c^T x, \quad \text{s.t.} \quad \mathbf{0} \leq x \leq \mathbf{1};$$

- (b) $\min_{x \in \mathbb{R}^n} c^T x, \quad \text{s.t.} \quad -\mathbf{1} \leq x \leq \mathbf{1};$
(c) $\min_{x \in \mathbb{R}^n} c^T x, \quad \text{s.t.} \quad -1 \leq \mathbf{1}^T x \leq 1;$
(d) $\min_{x \in \mathbb{R}^n} c^T x, \quad \text{s.t.} \quad \mathbf{1}^T x = 1, \quad x \geq 0;$

解 (邓展望).

(a) 问题可写为

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \sum_{i=1}^n c_i x_i \\ \text{s.t.} \quad & \mathbf{0} \leq x \leq \mathbf{1}, \end{aligned}$$

所以当 $c_i > 0$ 时 $x_i = 0$; 当 $c_i < 0$ 时 $x_i = 1$, 即 x 可写为

$$x = (x_1, \dots, x_n)^T, \quad x_i = \frac{1}{2} - \frac{1}{2} \text{sign}(c_i).$$

(b) 根据 (a) 的分析, 同理可知

$$x = (x_1, \dots, x_n)^T, \quad x_i = -\text{sign}(c_i).$$

(c) 由于问题可写为

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \sum_{i=1}^n c_i x_i \\ \text{s.t.} \quad & -1 \leq \mathbf{1}^T x \leq 1, \end{aligned}$$

所以若 $c_i \neq c_j$, 不妨设 $c_i > c_j$, 则取 $x_i = -z, x_j = z$, 其余分量为 0, 目标函数的值为 $-z(c_i - c_j) \rightarrow -\infty (z \rightarrow +\infty)$, 所以原问题无界.

该问题有解当且仅当 $c = m\mathbf{1}$, 其中 m 为常数.

(d) 问题可写为

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \sum_{i=1}^n c_i x_i \\ \text{s.t.} \quad & \mathbf{1}^T x = 1, \end{aligned}$$

设 c_j 为 $c_i (i = 1 \dots n)$ 中最小的项, 则有

$$\sum_{i=1}^n c_i x_i \geq \sum_{i=1}^n c_j x_i = c_j$$

即解为 $x = (0, \dots, 1, \dots, 0)$, 其中第 j 个分量取 1. □

3.3 在数据插值中, 考虑一个简单的复合模型 (取 ϕ 为恒等映射, 两层复合模型):

$$\min_{X_1 \in \mathbb{R}^{q \times p}, X_2 \in \mathbb{R}^{q \times q}} \sum_{i=1}^m \|X_2 X_1 a_i - b_i\|_2^2,$$

其中 $a_i \in \mathbb{R}^p, b_i \in \mathbb{R}^q, i = 1, 2, \dots, m$.

- (a) 试计算目标函数关于 X_1, X_2 的导数;
- (b) 试给出该问题的最优解.

解 (俞建江). 将 a_i, b_i 整合成矩阵 A, B :

$$A = (a_1, a_2, \dots, a_m) \in \mathbb{R}^{p \times m}, B = (b_1, b_2, \dots, b_m) \in \mathbb{R}^{q \times m},$$

则目标函数等价于

$$\begin{aligned} f(X_1, X_2) &= \sum_{i=1}^m \|X_2 X_1 a_i - b_i\|_2^2 \\ &= \|X_2 X_1 A - B\|_F^2 \\ &= \text{Tr}((X_2 X_1 A - B)^T (X_2 X_1 A - B)). \end{aligned}$$

- (a) 任取 $V \in \mathbb{R}^{q \times p}$ 以及 $t > 0$,

$$\begin{aligned} f(X_1 + tV, X_2) - f(X_1, X_2) &= 2t \text{Tr}((X_2 V A)^T (X_2 X_1 A - B)) + \mathcal{O}(t^2) \\ &= 2t \langle V, X_2^T (X_2 X_1 A - B) A^T \rangle + \mathcal{O}(t^2), \end{aligned}$$

$$\text{故 } \frac{\partial f}{\partial X_1} = 2X_2^T (X_2 X_1 A - B) A^T.$$

$$\text{类似地可得到 } \frac{\partial f}{\partial X_2} = 2(X_2 X_1 A - B) A^T X_1^T.$$

- (b) 令 $X = X_2 X_1$, $g(X) = \|XA - B\|_F^2$, 容易验证问题

$$\min_{X \in \mathbb{R}^{q \times p}} \|XA - B\|_F^2$$

与原问题等价. 令 $\frac{\partial g}{\partial X} = (XA - B)A^T = 0$, 即

$$A(A^T X^T - B^T) = 0,$$

显然这个方程有解, 且由于 $g(X) = AA^T$ 为半正定矩阵, 方程的解即为原问题的解. 设等价问题的解集为 C , 即原问题的最优解集是 $C_0 = \{(X_1, X_2) \mid X_2 X_1 \in C\}$.

□

3.4 给定数据点 $a_i \in \mathbb{R}^n, b_i \in \mathbb{R}, i = 1, 2, \dots, m$, 我们用二次函数拟合, 即求 $X \in \mathcal{S}^n, y \in \mathbb{R}^n, z \in \mathbb{R}$ 使得

$$b_i \approx f(a_i) = a_i^T X a_i + y^T a_i + z, \quad i = 1, 2, \dots, m.$$

这里假设数据点 $a_i \in \mathcal{B} = \{a \in \mathbb{R}^n \mid l \leq a \leq u\}$. 相应的最小二乘模型为

$$\sum_{i=1}^m (f(a_i) - b_i)^2.$$

此外, 对函数 f 有三个额外要求: (1) f 是凹函数; (2) f 在集合 \mathcal{B} 上是非负的, 即 $f(a) \geq 0, \forall a \in \mathcal{B}$; (3) f 在 \mathcal{B} 上是单调非减的, 即对任意的 $a, \hat{a} \in \mathcal{B}$ 且满足 $a \leq \hat{a}$, 有 $f(a) \leq f(\hat{a})$.

请将上述问题表示成一个凸优化问题, 并尽可能地简化.

解 (邓展望).

- 首先由于 f 为凹函数, 所以 X 为负半定矩阵, 即 $-X$ 为半正定矩阵.
- 由于 f 在 \mathcal{B} 上是单调非减的, 根据凹函数的理论可知, 凹函数在约束情况下的最小值只可能在边界取到所以约束为:

$$\text{设 } l = (l_1, l_2, \dots, l_m), u = (u_1, u_2, \dots, u_m),$$

$$x^T X x^T + y^T x + z \geq 0, x_i = l_i \text{ 或者 } u_i.$$

- 再根据单调非减性, 由于

$$\begin{aligned} f(a + \varepsilon) - f(a) &= (a + \varepsilon)^T X (a + \varepsilon) + y^T (a + \varepsilon) + z - a^T X a \\ &\quad - y^T a - z \\ &= 2\varepsilon X a + y^T \varepsilon \geq 0, \end{aligned}$$

其中 $\varepsilon \geq 0$, 因 ε 的任意性, 所以该不等式对任意 $a \in \mathcal{B}$ 均成立.

综上, 凸优化问题可写为

$$\begin{aligned} \min_{X \in \mathcal{S}, y \in \mathbb{R}^n, z \in \mathbb{R}} \quad & \sum_{i=1}^m (a_i^T X a_i - y^T a_i - z + b_i)^2. \\ \text{s.t.} \quad & X \geq 0, \\ & x^T X x + y^T x + z \geq 0, \quad x_i \in \{l_i, u_i\}, \\ & 2\varepsilon X a + y^T \varepsilon \geq 0, \quad \varepsilon \geq 0, \\ & a \in \mathcal{B}. \end{aligned}$$

□

3.5 考虑下面的复合优化问题:

$$\min_{x \in \mathbb{R}^n} \|x\|_1 + \|Dx - a\|_2^2,$$

其中 $a \in \mathbb{R}^n$, $D = \text{Diag}(d_1, d_2, \dots, d_n)$ 均已知. 试给出最优解 x^* 的表达式.

解 (邓展望). **注: 可参考课本 8.4.12**

由于对每个分量考虑, 原问题可化为

$$|x_i| + (d_i x_i - a_i)^2 = |x_i| + d_i^2 x_i^2 - 2a_i x_i d_i + a_i^2,$$

求解该问题则可给出 x^* 每个分量的表达式.

$$(a) \text{ 若 } -2d_i a_i + 1 \leq 0, \quad x_i^* = \frac{2d_i a_i - 1}{2d_i^2}.$$

$$(b) \text{ 若 } -2d_i a_i - 1 \geq 0, \quad x_i^* = \frac{1 + 2d_i a_i}{2d_i^2}.$$

$$(c) \text{ 否则 } x_i^* = 0.$$

□

3.6 考虑下面的复合优化问题:

$$\min_{x \in \mathbb{R}^n} \|x\|_0 + \|Dx - a\|_2^2,$$

其中 $a \in \mathbb{R}^n$, $D = \text{Diag}(d_1, d_2, \dots, d_n)$ 均已知. 试给出最优解 x^* 的表达式.

解 (邓展望). 按 4.5 题的方法, 先给出 x_i 的表达式为

$$g(x_i) = \delta(x_i) + (d_i x_i - a_i)^2,$$

其中 $\delta(x_i) = 1$ 当且仅当 $x_i \neq 0$, 否则取 0. 则最优解分量 x_i^* 的表达式为:

(a) 若 $d_i = 0$, 则 $x_i^* = 0$.

(b) 若 $d_i \neq 0$,

i. 若 $|a_i| \leq 1$, 取 $x_i^* = 0$ 较小, 此时满足

$$g(0) \leq g(x_i). \quad (x_i \neq 0)$$

ii. 若 $|a_i| > 1$, 取使得 $(d_i x_i - a_i)^2$ 最小的非零的 x_i 即可, 那么

$$x_i^* = \frac{a_i}{d_i}. \quad \square$$

3.7 将不等式形式的半定规划问题 (4.5.1) 转化成标准形式 (4.5.2).

解 (俞建江). 将原问题先化为:

$$\begin{aligned} \min_{y \in \mathbb{R}^m} \quad & -b^T y, \\ \text{s.t.} \quad & \sum_{i=1}^m y_i A_i \preceq C. \end{aligned} \quad (3.1)$$

我们可以求其对偶问题. 对不等式约束引入乘子 $X \in \mathcal{S}^n$ 并且 $X \succeq 0$, 拉格朗日函数为

$$\begin{aligned} L(y, X) &= -b^T y + \left\langle X, \left(\sum_{i=1}^m y_i A_i \right) - C \right\rangle, \\ &= \sum_{i=1}^m y_i (-b_i + \langle A_i, X \rangle) - \langle C, X \rangle. \end{aligned}$$

因为上式对 y 是仿射的, 故对偶函数可以描述为

$$g(X) = \inf_y L(y, X) = \begin{cases} -\langle C, X \rangle, & \langle A_i, X \rangle = b_i, \quad i = 1, 2, \dots, m, \\ -\infty, & \text{其它}. \end{cases}$$

因此对偶问题可以写成

$$\begin{aligned} \min_{X \in \mathcal{S}^n} \quad & \langle C, X \rangle, \\ \text{s.t.} \quad & \langle A_i, X \rangle = b_i, \quad i = 1, 2, \dots, m, \\ & X \succeq 0. \end{aligned} \quad (3.2) \quad \square$$

3.8 对于对称矩阵 $C \in \mathcal{S}^n$, 记其特征值分解为 $C = \sum_{i=1}^n \lambda_i u_i u_i^T$, 假设

$$\lambda_1 \geq \cdots \geq \lambda_m > 0 > \lambda_{m+1} \geq \cdots \geq \lambda_n,$$

考虑如下半定规划问题:

$$\begin{aligned} \min_{X \in \mathcal{S}^n} \quad & \langle C, X \rangle, \\ \text{s.t.} \quad & u_i^T X u_i = 0, i = m+1, m+2, \cdots, n, \\ & X \succeq 0. \end{aligned}$$

试给出该问题最优解的表达式.

解 (俞建江). 最优解为 $X = 0$, 证明如下.

考虑

$$\begin{aligned} \langle C, X \rangle &= \text{Tr}(C^T X) \\ &= \text{Tr}\left(\sum_{i=1}^n \lambda_i u_i u_i^T X\right) \\ &= \sum_{i=1}^n \lambda_i \text{Tr}(u_i^T X u_i), \end{aligned}$$

由约束条件 $u_i^T X u_i = 0 (i = m+1, m+2, \cdots, n)$ 得 $\langle C, X \rangle \geq 0$ 当且仅当 $u_i^T X u_i = 0 (i = 1, 2, \cdots, m)$ 时取到等号. 记 $T = (u_1, u_2, \cdots, u_n)$,

$$\begin{aligned} \text{Tr}(u_i^T X u_i) &= 0 \quad (1 \leq i \leq n), \\ \Rightarrow \text{Tr}(u_i u_i^T X) &= 0 \quad (1 \leq i \leq n), \\ \Rightarrow \text{Tr}(T T^T X) &= 0 \\ \Rightarrow \text{Tr}(X) &= 0, \end{aligned}$$

又 $X \succeq 0$, 因此 $\text{Tr}(X) = 0$ 说明 $X = 0$. □

3.9 如果在最大割问题 (4.5.6) 中, 约束 $x_j \in \{-1, 1\}$ 改为 $x_j \in \{0, 1\}$, 即对应优化问题

$$\begin{aligned} \max \quad & \frac{1}{2} \sum_{i < j} w_{ij} (1 - x_i x_j), \\ \text{s.t.} \quad & x_j \in \{0, 1\}, j = 1, 2, \cdots, n. \end{aligned}$$

试给出其一个半定规划松弛.

解 (俞建江). 记 $W = (w_{ij})_{n \times n}$, 作变量替换 $y = 2x - \mathbf{1}$, 消去常数后原问题等价于

$$\begin{aligned} \min \quad & y^T W y + 2b^T y + c \\ \text{s.t.} \quad & y_i \in \{-1, 1\}, \quad i = 1, 2, \dots, n, \end{aligned}$$

其中 $b = \frac{1}{2}(W + W^T)\mathbf{1}$, $c = -\mathbf{3}\mathbf{1}^T W \mathbf{1}$. 这等价于

$$\begin{aligned} \min \quad & \left\langle \begin{pmatrix} W & b \\ b^T & c \end{pmatrix}, \begin{pmatrix} Y & y \\ y^T & 1 \end{pmatrix} \right\rangle \\ \text{s.t.} \quad & Y = yy^T, Y_{ii} = 1, \quad i = 1, 2, \dots, n. \end{aligned}$$

将 $Y = yy^T$ 松弛为 $Y \succeq yy^T$, 又等价于 $\begin{pmatrix} Y & y \\ y^T & 1 \end{pmatrix} \succeq 0$. 因此得到松弛形式

$$\begin{aligned} \min \quad & \langle \overline{W}, \overline{Y} \rangle \\ \text{s.t.} \quad & \overline{Y} \succeq 0, \quad \overline{Y}_{ii} = 1, \quad i = 1, 2, \dots, n+1. \end{aligned}$$

□

第四章 最优性理论

4.1 考虑优化问题

$$\min_{x \in \mathbb{R}^n} x^T A x + 2b^T x,$$

其中 $A \in \mathcal{S}^n$, $b \in \mathbb{R}^n$. 为了保证该问题最优解存在, A, b 需要满足什么性质?

解 (邓展望). A, b 需要满足 A 为半正定矩阵并且 $b \in \mathcal{R}(A)$ (即 b 位于 A 的像空间中). 实际上这也为充要条件. 定义

$$m(x) = \frac{1}{2} x^T A x + x^T b \quad (4.1)$$

则我们有:

\Leftarrow : 由于 $g \in \mathcal{R}(B)$, 所以存在 p^* 满足 $Ap^* = -b$, 所以对任意 $\omega \in \mathbb{R}^n$, 我们都有

$$\begin{aligned} m(p^* + \omega) &= b^T (p^* + \omega) + \frac{1}{2} (p^* + \omega)^T A (p^* + \omega) \\ &= \left(b^T p^* + \frac{1}{2} p^{*\top} A p^* \right) + b^T \omega + (Ap^*)^T \omega + \frac{1}{2} \omega^T A \omega \\ &= m(p^*) + \frac{1}{2} \omega^T A \omega \geq m(p^*), \end{aligned}$$

由此可知 p^* 是 $m(p)$ 的最小值.

\Rightarrow : 若 p^* 是 $m(p)$ 的最小值, 所以 $\nabla m(p^*) = Ap^* + b = 0$, $b \in \mathcal{R}(A)$. 再由于 $\nabla^2 m(p^*) = A$ 为半正定矩阵, 结果得证.

□

4.2 试举例说明对无约束光滑优化问题, 二阶必要条件不是充分的, 二阶充分条件也不是必要的 (见定理 5.4).

解 (陈钺). 考虑 $f(x) = x^3$, 在零点处满足二阶必要条件 $f'(x) = 3x^2 = 0$, $f''(x) = 6x = 0$. 而 $f(x)$ 是没有局部极小点的, 0 点不是 $f(x)$ 的局部极小点, 这说明二阶必要条件不充分.

再考虑 $f(x) = x^4$, 由于 $f(x)$ 是对称的, 显然在 0 点处有极小点, 而 $f'(x) = 0$, $f''(x) = 0$, 不满足二阶充分条件 ($\nabla^2 f(x)$ 正定). 这说明二阶充分条件不必要. \square

4.3 证明下列锥是自对偶锥:

- (a) 半正定锥 $\{X \mid X \succeq 0\}$ (全空间为 \mathcal{S}^n);
- (b) 二次锥 $\{(x, t) \in \mathbb{R}^{n+1} \mid t \geq \|x\|_2\}$ (全空间为 \mathbb{R}^{n+1}).

解 (陈钺).

- (a) 半正定锥 $\{X \mid X \succeq 0\}$ (全空间为 \mathcal{S}^n) 是自对偶锥.

该命题等价于证明, Y 对于任意半正定矩阵 X 有 $\langle X, Y \rangle \geq 0$ 成立 $\Leftrightarrow Y$ 是半正定矩阵.

\Rightarrow : 若 $Y \in \mathcal{S}^n$ 满足对于任意半正定矩阵 X , 有 $\langle X, Y \rangle \geq 0 \Leftrightarrow Y \succeq 0$. 考虑 $X = qq^T$, $q \in \mathbb{R}^n$, 得

$$\langle X, Y \rangle = \text{tr}(XY) = \text{tr}(qq^T Y) = \text{tr}(q^T Y q) = q^T Y q.$$

由 $\langle X, Y \rangle \geq 0$ 可得, $q^T Y q \geq 0$ 对于任意 $q \in \mathbb{R}^n$, 这说明 Y 是半正定矩阵.

\Leftarrow : 令 X, Y 都是半正定矩阵, 则 X 有分解形式 $X = QQ^T$, $Q = (q_1, q_2, \dots, q_n)$. 则

$$\begin{aligned} \langle X, Y \rangle &= \text{tr}(XY) \\ &= \text{tr}(QQ^T Y) \\ &= \text{tr}(Q^T Y Q) \\ &= \sum_{i=1}^n q_i^T Y q_i. \end{aligned}$$

由于 Y 是半正定的, 因此 $\langle X, Y \rangle \geq 0$.

- (b) 二次锥 $\{(x, t) \in \mathbb{R}^{n+1} \mid t \geq \|x\|_2\}$ (全空间为 \mathbb{R}^{n+1}).

令 $\mathcal{I} = \{(x, t) \in \mathbb{R}^{n+1} \mid t \geq \|x\|_2\}$. 我们要证明

$$(x', t') \in \mathcal{I} \Leftrightarrow \langle x', x \rangle + t't \geq 0, \forall (x, t) \in \mathcal{I}.$$

\Rightarrow : 若 $(x', t') \in \mathcal{I}$, 即 $t' \geq \|x'\|_2$, 对于任意 $(x, t) \in \mathcal{I}$, 我们有

$$tt' \geq \|x'\|_2 \|x\|_2 \geq |\langle x', x \rangle|,$$

由此得到 $tt' + \langle x', x \rangle \geq 0$.

\Leftarrow : 若对于任意 $(x, t) \in \mathcal{I}$, (x', t') 满足 $tt' + \langle x', x \rangle \geq 0$. 注意到 $(-x', \|x'\|_2) \in \mathcal{I}$, 因此 $\|x'\|_2 t' + \langle x', -x' \rangle \geq 0$, 得到 $t' \geq \|x'\|_2$, 即 $(x', t') \in \mathcal{I}$. \square

4.4 考虑优化问题

$$\min_{x \in \mathbb{R}^n} x^T A x + 2b^T x, \quad \text{s.t.} \quad \|x\|_2 \leq \Delta,$$

其中 $A \in \mathcal{S}_{++}^n$, $b \in \mathbb{R}^n$, $\Delta > 0$. 求出该问题的最优解.

解 (陈钺). 原问题满足 Slater 条件. 注意到原问题的约束等价于 $x^T x \leq \Delta^2$. 由此我们得到原问题的 KKT 条件:

$$Ax + b + \mu x = 0,$$

$$\mu(x^T x - \Delta^2) = 0,$$

$$\mu \geq 0.$$

KKT 条件给出了原问题最优解的两种可能, 即 $\mu = 0$ 的情况下满足 $Ax + b = 0$, 或者 $x^T x - \Delta^2 = 0$ 成立.

由于 $\|A^{-1}b\|$ 是原目标函数在约束情况下的最优解, 因此若 $\|A^{-1}b\| \leq \Delta$, 则 $x = A^{-1}b$ 是最优解.

若 $\|A^{-1}b\| > \Delta$, 则原问题的最优解即等式约束下的最优解是

$$\min_{x \in \mathbb{R}^n} x^T A x + 2b^T x, \quad \text{s.t.} \quad \|x\|_2 = \Delta. \quad \square$$

4.5 考虑函数 $f(x) = 2x_1^2 + x_2^2 - 2x_1x_2 + 2x_1^3 + x_1^4$, 求出其所有一阶稳定点, 并判断它们是否为局部最优点 (极小或极大)、鞍点或全局最优点?

解 (陈钺). 首先计算 $f(x)$ 关于 x_1, x_2 的梯度.

$$\begin{aligned} \frac{df(x)}{dx_1} &= 4x_1 - 2x_2 + 6x_1^2 + 4x_1^3, \\ \frac{df(x)}{dx_2} &= 2x_2 - 2x_1. \end{aligned}$$

对于一阶稳定点, 令上述两式为 0, 我们得到

$$\begin{aligned} x_1 &= x_2, \\ x_1(1 + 3x_1 + 2x_1^2) &= 0. \end{aligned}$$

由此得到三个一阶稳定点 $(x_1, x_2) = (0, 0)$, $(-1, -1)$ 或 $(-0.5, -0.5)$. 再考虑海瑟矩阵

$$\nabla^2 f(x) = \begin{bmatrix} 4 + 12x_1 + 12x_1^2 & -2 \\ -2 & 2 \end{bmatrix},$$

有

$$\begin{aligned} \nabla^2 f(0, 0) &= \nabla^2 f(-1, -1) = \begin{bmatrix} 4 & -2 \\ -2 & 2 \end{bmatrix}, \\ \nabla^2 f(-0.5, -0.5) &= \begin{bmatrix} 1 & -2 \\ -2 & 2 \end{bmatrix}. \end{aligned}$$

注意到 $(0, 0)$ 和 $(-1, -1)$ 处海瑟矩阵都是正定矩阵. 因此都是局部最优. 又根据 $f(0, 0) = f(-1, -1) = 0$ 知这两个点也为全局最优. 另一方面, $(-0.5, -0.5)$ 处的海瑟矩阵为不定矩阵, 因此是一个鞍点. \square

4.6 给出下列优化问题的显式解:

- (a) $\min_{x \in \mathbb{R}^n} c^T x, \quad \text{s.t.} \quad Ax = b, \quad \text{其中 } A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m;$
- (b) $\min_{x \in \mathbb{R}^n} \|x\|_2, \quad \text{s.t.} \quad Ax = b;$
- (c) $\min_{x \in \mathbb{R}^n} c^T x, \quad \text{s.t.} \quad \mathbf{1}^T x = 1, x \geq 0;$
- (d) $\min_{X \in \mathbb{R}^{m \times n}} \|X\|_* + \frac{1}{2} \|X - Y\|_F^2, \quad \text{其中 } Y \in \mathbb{R}^{m \times n} \text{ 是已知的.}$

解 (陈铨, 邓展望).

- (a) 注意到 $Ax = b$ 的解的集合可以表示为 $\{x \mid x = \eta + \xi, A\xi = 0\}$, 其中 η 是 $Ax = b$ 的一个特解.
由此可知, 若存在 ξ 满足 $A\xi = 0, c^T \xi \neq 0$, 则没有最优解. 反之, 只有当 c 在 $Ax = 0$ 的解空间对应的正交子空间中时, 才有最小值. 且此时 x 是任意满足 $Ax = b$ 的解.

- (b) 对于这一问题, 不妨设 A 是行满秩的, 且目标函数等价于 $\frac{1}{2}\|x\|_2^2$. 我们引入拉格朗日乘子 λ , 构造拉格朗日函数

$$L(x, \lambda) = \frac{1}{2}\|x\|_2^2 + \lambda^T(Ax - b).$$

由于问题只有仿射约束, Slater 条件满足. 对于全局最优解 x^* , 当且仅当存在 λ^* 满足

$$\begin{cases} x^* + A^T \lambda = 0, \\ Ax^* = b. \end{cases}$$

对于第一行公式同时左乘 A , 得到

$$Ax^* + AA^T \lambda = 0,$$

由于 A 是行满秩的, 所以 AA^T 是满秩矩阵, 有 $\lambda = -(AA^T)^{-1}b$. 则得到

$$x^* = A^T(AA^T)^{-1}b.$$

- (c) 设 i 为 c 的最小分量的下标, 则 $x = e_i$, 即 x 为第 i 个分量为 1 的单位向量.
- (d) 令 Y 有奇异值分解 $Y = U\tilde{\Sigma}V^T$. 令 $X = UZV^T$, X 与 Z 有相同的奇异值. 由于正交变换不改变 F 范数, 则有

$$\|X\|_* + \frac{1}{2}\|X - Y\|_F^2 = \|Z\|_* + \frac{1}{2}\|Z - \tilde{\Sigma}\|_F^2.$$

可以证明, 当 Z 的奇异值 Σ 确定时, 只有在 $Z = \Sigma$ 时, $\|Z - \tilde{\Sigma}\|_F^2$ 最小. 因此原问题转化为

$$\min_{\sigma_i \geq 0} \sum_{i=1}^r \sigma_i + \sum_{i=1}^r \frac{1}{2}(\sigma_i - \tilde{\sigma})^2,$$

其中 $\tilde{\sigma}$ 是 Y 的特征值. 我们可以得到 $\sigma_i = \max\{0, \tilde{\sigma}_i - 1\}$. 由此得到最优解 $X = U\Sigma V^T$, Σ 为对角矩阵且第 i 个对角元为 $\sigma_i = \max(0, \tilde{\sigma}_i - 1)$. \square

4.7 计算下列优化问题的对偶问题.

- (a) $\min_{x \in \mathbb{R}^n} \|x\|_1, \quad \text{s.t.} \quad Ax = b;$

- (b) $\min_{x \in \mathbb{R}^n} \|Ax - b\|_1;$
 (c) $\min_{x \in \mathbb{R}^n} \|Ax - b\|_\infty;$
 (d) $\min_{x \in \mathbb{R}^n} x^T Ax + 2b^T x, \quad \text{s.t.} \quad \|x\|_2^2 \leq 1, \text{ 其中 } A \text{ 为正定矩阵.}$

解 (陈钺).

(a) 引入拉格朗日乘子 λ , 构造拉格朗日函数

$$L(x, \lambda) = \|x\|_1 + \lambda^T (Ax - b),$$

由于是等式约束, 可得 $\lambda \in \mathbb{R}^m$. 对于确定的 λ , 令 $c = A^T \lambda$, 则有

$$L(x, \lambda) = \sum_{i=1}^n (|x_i| + c_i x_i) - \lambda^T b$$

由于 x 是任取的, 因此为了使得 $\min_x L(x, \lambda)$ 存在, 需要满足 $|c_i| \leq 1$, 即 $\|A^T \lambda\|_\infty \leq 1$. 在这一条件下, x_i 取零即为最小值. 由此得到对偶问题

$$\begin{aligned} \max \quad & -b^T \lambda, \\ \text{s.t.} \quad & \|A^T \lambda\|_\infty \leq 1. \end{aligned}$$

(b) 令 $y = Ax - b$, 原优化问题等价于

$$\begin{aligned} \max \quad & \|y\|_1, \\ \text{s.t.} \quad & Ax - y = b. \end{aligned}$$

引入拉格朗日乘子 λ , 构造拉格朗日函数

$$L(x, y, \lambda) = \|y\|_1 + \lambda^T (Ax - y - b),$$

只有在 $A^T \lambda = 0$ 且 $|\lambda_i| \leq 1$ 时 $\min_{x, y} L(x, y, \lambda)$ 存在. 此时

$$\min_{x, y} L(x, y, \lambda) = -b^T \lambda$$

由此得到对偶问题

$$\begin{aligned} \max \quad & -b^T \lambda, \\ \text{s.t.} \quad & \|\lambda\|_\infty \leq 1, \\ & A^T \lambda = 0. \end{aligned}$$

(c) 上述问题等价于

$$\begin{aligned} \min \quad & y, \\ \text{s.t.} \quad & Ax - b \leq y\mathbf{1}. \\ & Ax - b \leq -y\mathbf{1} \end{aligned}$$

引入拉格朗日乘子 λ_1, λ_2 , 构造拉格朗日函数

$$L(x, y, \lambda_1, \lambda_2) = y + \lambda_1^T (Ax - b - y\mathbf{1}) + \lambda_2^T (Ax - b + y\mathbf{1}),$$

且不等式的拉格朗日乘子非负, 即 $\lambda_1 \geq 0, \lambda_2 \geq 0$. 为使得最小值有限, 需要使得 x, y 的系数都为零, 即得到

$$A^T(\lambda_1 + \lambda_2) = 0, \quad \lambda_1^T \mathbf{1} + \lambda_2^T \mathbf{1} + 1 = 0.$$

由此得到对偶问题

$$\begin{aligned} \max \quad & -b^T(\lambda_1 + \lambda_2), \\ \text{s.t.} \quad & A^T(\lambda_1 + \lambda_2) = 0, \\ & -\lambda_1^T \mathbf{1} + \lambda_2^T \mathbf{1} + 1 = 0. \end{aligned}$$

(d) 引入拉格朗日乘子 λ , 构造拉格朗日函数

$$L(x, \lambda) = x^T Ax + 2b^T x + \lambda(x^T x - 1) = x^T (A + \lambda I)x + 2b^T x - \lambda.$$

当 $A + \lambda I$ 正定时, $\min_x L(x, \lambda)$ 存在, 而 A 是正定的, 因此有 $\lambda \geq 0$.

在这一条件下, $x = -(A + \lambda I)^{-1}b$ 得到最小值. 此时有

$$\min_x L(x, \lambda) = -b^T (A + \lambda I)^{-1} b - \lambda.$$

由此得到对偶问题

$$\begin{aligned} \max \quad & -b^T (A + \lambda I)^{-1} b - \lambda, \\ \text{s.t.} \quad & \lambda \geq 0. \end{aligned}$$

□

4.8 如下论断正确吗? 为什么?

对等式约束优化问题

$$\begin{aligned} \min \quad & f(x), \\ \text{s.t.} \quad & c_i(x) = 0, \quad i \in \mathcal{E}. \end{aligned}$$

考虑与之等价的约束优化问题:

$$\begin{aligned} \min \quad & f(x), \\ \text{s.t.} \quad & c_i^2(x) = 0, \quad i \in \mathcal{E}. \end{aligned} \quad (4.2)$$

设 x^\sharp 是上述问题的一个 KKT 点, 根据 (5.5.8) 式, x^\sharp 满足

$$\begin{aligned} 0 &= \nabla f(x^\sharp) + 2 \sum_{i \in \mathcal{E}} \lambda_i^\sharp c_i(x^\sharp) \nabla c_i(x^\sharp), \\ 0 &= c_i(x^\sharp), \quad i \in \mathcal{E}, \end{aligned}$$

其中 λ_i^\sharp 是相应的拉格朗日乘子. 整理上式得 $\nabla f(x^\sharp) = 0$. 这说明对等式约束优化问题, 我们依然能给出类似无约束优化问题的最优性条件.

解 (邓展望). 此处用到了 (5.5.8) 式, 也即一般约束优化问题的最优性条件. 但是该定理需要满足

$$T_{\mathcal{X}}(x^\sharp) = \mathcal{F}(x^\sharp).$$

容易验证 $\mathcal{F}(x^\sharp) = \mathbb{R}^d$ (d 为 x 的维数). 由于 $c_i(x^\sharp) = 0$, 其可行域一般是 \mathbb{R}^d 的真子空间, 那么 $T_{\mathcal{X}}(x^\sharp)$ 也应为 \mathbb{R}^d 中的子空间 (平面), 故一般 $T_{\mathcal{X}}(x^\sharp) \neq \mathbb{R}^d$.

综上所述, 若不满足 KKT 条件所需的约束品性, 就不能用 KKT 条件去推导原问题的最优性条件. 因此这种说法是错误的. \square

4.9 证明: 若在点 x 处线性约束品性 (见定义 5.11) 满足, 则有 $T_{\mathcal{X}}(x) = \mathcal{F}(x)$.

解 (陈铖). 我们知道 $T_{\mathcal{X}}(x) \subseteq \mathcal{F}(x)$, 只需证明在线性约束品性下, 若 $d \in \mathcal{F}(x)$, 则有 $d \in T_{\mathcal{X}}(x)$.

由于约束都是线性约束, 可以写成如下形式

$$\begin{cases} A_1 x = b_1, \\ A_2 x \leq b_2. \end{cases}$$

令 $d \in \mathcal{F}(x)$ 为任一线性化可行方向, 令 $\mathcal{A}(x)$ 为积极集, 此时不等式约束中取等号的约束对应的矩阵 A_2 的部分记为 A'_2 , 则我们知道 d 满足

$$A_1 d = 0, \quad A'_2 d \leq 0.$$

取 $z^k = x + t^k d$, $\{t^k\}$ 为一组正标量且 $\lim_{k \rightarrow \infty} t^k = 0$. 注意到 z^k 一定满足等式约束, 且有

$$A'_2 z^k = A'_2 x + t^k A'_2 d = t^k A'_2 d \leq 0,$$

当 t^k 取到较小的值时, x 处未取到等号的不等式约束在 z^k 上也满足. 因此可以得到 $z^k \in \mathcal{X}$. 而我们显然有

$$\lim_{k \rightarrow \infty} \frac{z^k - x}{t^k} = d.$$

因此得到 $d \in T_{\mathcal{X}}(x)$. □

4.10 考虑优化问题

$$\begin{aligned} \min_{x \in \mathbb{R}^2} \quad & x_1, \\ \text{s.t.} \quad & 16 - (x_1 - 4)^2 - x_2^2 \geq 0, \\ & x_1^2 + (x_2 - 2)^2 - 4 = 0. \end{aligned}$$

求出该优化问题的 KKT 点, 并判断它们是否是局部极小点、鞍点以及全局极小点?

解 (陈钺). 构造拉格朗日函数

$$L(x, \lambda, \nu) = x_1 + \nu(x_1^2 + (x_2 - 2)^2 - 4) - \lambda(16 - (x_1 - 4)^2 - x_2^2),$$

对 x_1 , x_2 分别求导, 得到稳定性条件

$$\begin{aligned} 1 + 2\nu x_1 + 2\lambda(x_1 - 4) &= 0, \\ 2\nu(x_2 - 2) + 2\lambda x_2 &= 0. \end{aligned}$$

分别考虑互补松弛条件的两种情况, 即 $\lambda = 0$ 或 $16 - (x_1 - 4)^2 - x_2^2 = 0$. 若互补松弛条件要求 $\lambda = 0$, 则稳定性条件变为

$$\begin{aligned} 1 + 2\nu x_1 &= 0, \\ 2\nu(x_2 - 2) &= 0. \end{aligned}$$

由第一行公式知 $\nu \neq 0$, 因此得到 $x_2 = 2$. 此时需要再考虑等式约束的可行性条件

$$x_1^2 + (x_2 - 2)^2 - 4 = 0,$$

得到 $x_1 = \pm 2$. 此时得到 KKT 点 $(x_1, x_2, \lambda, \nu) = (\pm 2, 2, 0, \mp \frac{1}{4})$. 而 $x_1 = -2$ 且 $x_2 = 2$ 不满足条件, 因此取得 KKT 点 $(x_1, x_2, \lambda, \nu) = (2, 2, 0, -\frac{1}{4})$.

若互补松弛条件要求 $16 - (x_1 - 4)^2 - x_2^2 = 0$, 又有 $x_1^2 + (x_2 - 2)^2 - 4 = 0$, 综合两式得到 (x_1, x_2) 的两个解 $(0, 0), (\frac{8}{5}, \frac{16}{5})$. 根据这两个解可得 KKT 点 $(x_1, x_2, \lambda, \nu) = (0, 0, \frac{1}{8}, 0), (\frac{8}{5}, \frac{16}{5}, \frac{3}{40}, -\frac{1}{5})$.

注意 $L(x, \lambda, \nu)$ 关于 x 的海瑟矩阵为对角元均等于 $2(\lambda + \nu)$ 的对角矩阵, 因此 $(0, 0, \frac{1}{8}, 0)$ 为局部极小点, 也是全局极小点. 其他的 KKT 点均为局部极大点, 没有鞍点. \square

解 (陈钺). 对 X 和 S 分别进行对角化 $X = Q\Lambda_1 Q^T, S = R\Lambda_2 R^T$. 则有

$$\langle X, S \rangle = \text{Tr}((XS)) = \text{Tr}((Q\Lambda_1 Q^T R\Lambda_2 R^T)) = \text{Tr}((\Lambda_1 Q^T R\Lambda_2)) = 0,$$

其中 Λ_1, Λ_2 是对角矩阵, 且对角元素从大到小排列. 由此可以得到 $q_1^T r_1 = 0$.

注意到对非零特征值对应的特征向量更换位置, 如将 R 的第二列更换到第一列, 同样可得到 $q_1^T q_2 = 0$, 因此我们可以得到 $q_i^T r_j = 0, q_i$ 为 X 的任意非零特征向量, r_j 为 S 的任意非零特征向量.

由此我们得到

$$\Lambda_1 Q^T R \Lambda_2 = 0.$$

又有

$$XS = 0 \Leftrightarrow Q\Lambda_1 Q^T R\Lambda_2 R^T = 0 \Leftrightarrow \Lambda_1 Q^T R\Lambda_2 = 0,$$

命题得证. \square

4.11 考虑等式约束的最小二乘问题

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2, \quad \text{s.t. } Gx = h,$$

其中 $A \in \mathbb{R}^{m \times n}$ 且 $\text{rank}(A) = n$, $G \in \mathbb{R}^{p \times n}$ 且 $\text{rank}(G) = p$.

(a) 写出该问题的对偶问题;

(b) 给出原始问题和对偶问题的最优解的显式表达式.

解 (陈钺). (a) 不妨将等式约束写作 $2Gx = 2h$. 引入拉格朗日乘子 λ , 构造拉格朗日函数

$$\begin{aligned} L(x, \lambda) &= \|Ax - b\|_2^2 + 2\lambda^T(Gx - h) \\ &= x^T A^T A x - 2(b^T A - \lambda^T G)x + b^T b - 2\lambda^T h. \end{aligned}$$

固定 λ , $x = (A^T A)^{-1}(A^T b - G^T \lambda)$ 使拉格朗日函数取到最优解, 此时

$$\min_x L(x, \lambda) = -(A^T b - G^T \lambda)^T (A^T A)^{-1} (A^T b - G^T \lambda) + b^T b - 2\lambda^T h.$$

由此得到对偶问题

$$\max_{\lambda \in \mathbb{R}^p} -\lambda^T G(A^T A)^{-1} G^T \lambda + 2b^T A(A^T A)^{-1} G^T \lambda - 2h^T \lambda.$$

(b) 考虑原始问题的 KKT 条件

$$\begin{cases} 2A^T A x - 2A^T b + 2G^T \lambda = 0, \\ Gx = h. \end{cases}$$

由于 $A^T A$ 满秩, 得到 $x = (A^T A)^{-1}(A^T b - G^T \lambda)$. 带入第二个条件, 得到

$$G(A^T A)^{-1}(A^T b - G^T \lambda) = h,$$

因此 $\lambda = (G(A^T A)^{-1} G^T)^{-1}(G(A^T A)^{-1} A^T b - h)$. 进一步得到 x 的显式解为

$$x = (A^T A)^{-1}(A^T b - G^T (G(A^T A)^{-1} G^T)^{-1}(G(A^T A)^{-1} A^T b - h)).$$

对偶问题则为简单的无约束问题, 最优解的显式表达式为

$$\lambda^* = (G(A^T A)^{-1} G^T)^{-1}(G(A^T A)^{-1} A^T b - h). \quad \square$$

4.12 考虑优化问题

$$\min_{x \in \mathbb{R}^n} x^T A x + 2b^T x, \quad \text{s.t.} \quad \|x\|_2 \leq 1,$$

其中 $A \in \mathcal{S}^n$, $b \in \mathbb{R}^n$. 写出该问题的对偶问题, 以及对偶问题的对偶问题.

解 (陈铖). 引入拉格朗日乘子 λ , 约束等价于 $x^T x \leq 1$, 构造拉格朗日函数

$$L(x, \lambda) = x^T A x + 2b^T x + \lambda(x^T x - 1) = x^T (A + \lambda I) x + 2b^T x - \lambda.$$

为使得 $\min_x L(x, \lambda)$ 存在, 要求 $A + \lambda I$ 正定, 即 $\lambda > -\lambda_{\min}(A)$. 此时 $x = -(A + \lambda I)^{-1} b$ 取到最小值, 由此得到

$$\min_x L(x, \lambda) = -b^T (A + \lambda I)^{-1} b - \lambda.$$

令 A 有特征值分解 $A = Q \Sigma Q^T$, $c = Q^T b$, 则上式可写作

$$\begin{aligned} \min_x L(x, \lambda) &= -c^T (\Sigma + \lambda I)^{-1} c - \lambda \\ &= -\sum_{i=1}^n \frac{c_i^2}{\lambda + \sigma_i} - \lambda, \end{aligned}$$

由此得到对偶问题

$$\begin{aligned} \max_{\lambda \in \mathbb{R}} \quad & -\sum_{i=1}^n \frac{c_i^2}{\lambda + \sigma_i} - \lambda \\ \text{s.t.} \quad & \lambda > -\sigma_i, i = 1, 2, \dots, n. \end{aligned}$$

注意到 λ 趋近于 $-\sigma_i$ 时目标函数趋近于负无穷, 因此可以将不等式约束改为 $\lambda \geq -\sigma_i$. 引入变量 $z_i = \lambda + \sigma_i$, 原问题等价于

$$\begin{aligned} \max_{\lambda \in \mathbb{R}, z \in \mathbb{R}^n} \quad & -\sum_{i=1}^n \frac{c_i^2}{z_i} - \lambda \\ \text{s.t.} \quad & z_i - \lambda = \sigma_i, \\ & z_i \geq 0, i = 1, 2, \dots, n. \end{aligned}$$

考虑这一问题的对偶问题, 引入对应于等式约束的拉格朗日乘子 ν , 和对应于不等式约束的拉格朗日乘子 μ , 则有

$$L(z, \lambda, \nu, \mu) = -\sum_{i=1}^n \frac{c_i^2}{z_i} - \lambda - \mu^T z - \nu^T (z - \lambda \mathbf{1} - \sigma).$$

为使得 $\max_{\lambda, z} L(z, \lambda, \nu, \mu)$ 存在, 则需要满足

$$\mathbf{1}^T \nu = 1, \quad \nu + \mu > 0.$$

由此得到

$$\max_{\lambda, z} L(z, \lambda, \nu, \mu) = -2 \sum_{i=1}^n |c_i| \sqrt{\mu_i + \nu_i} + \sigma^T \nu,$$

因此对偶问题为

$$\begin{aligned} \min \quad & -2 \sum_{i=1}^n |c_i| \sqrt{\mu_i + \nu_i} + \sigma^T \nu \\ \text{s.t.} \quad & \mathbf{1}^T \nu = 1, \\ & \nu + \mu \geq 0, \\ & \nu \geq 0. \end{aligned}$$

注意到 μ 是任取的, 则 $\nu + \mu$ 可以为 0, 因此上述问题等价于

$$\begin{aligned} \min \quad & \sigma^T \nu \\ \text{s.t.} \quad & \mathbf{1}^T \nu = 1, \\ & \nu \geq 0. \end{aligned} \quad \square$$

4.13 考虑支持向量机问题

$$\begin{aligned} \min_{x \in \mathbb{R}^n, \xi} \quad & \frac{1}{2} \|x\|_2^2 + \mu \sum_{i=1}^m \xi_i, \\ \text{s.t.} \quad & b_i a_i^T x \geq 1 - \xi_i, \quad i = 1, 2, \dots, m, \\ & \xi_i \geq 0, \quad i = 1, 2, \dots, m, \end{aligned}$$

其中 $\mu > 0$ 为常数且 $b_i \in \mathbb{R}$, $a_i \in \mathbb{R}^n$, $i = 1, 2, \dots, m$ 是已知的. 写出该问题的对偶问题.

解 (陈钺). 引入对应于第一条约束的拉格朗日乘子 λ , 和对应于 $\xi_i \geq 0$ 约束的拉格朗日乘子 ν , 构造拉格朗日函数

$$\begin{aligned} L(x, \xi, \lambda, \nu) &= \frac{1}{2} \|x\|_2^2 + \mu \sum_{i=1}^m \xi_i - \sum_{i=1}^m \lambda_i (b_i a_i^T x - 1 + \xi_i) - \sum_{i=1}^m \nu_i \xi_i \\ &= \frac{1}{2} \|x\|_2^2 - \left(\sum_{i=1}^m \lambda_i b_i a_i^T \right) x + \sum_{i=1}^m (\mu - \lambda_i - \nu_i) \xi_i + \sum_{i=1}^m \lambda_i. \end{aligned}$$

为使得 $\min_{x,\xi} L(x,\xi,\lambda,\nu)$ 存在, 要求有 $\mu - \lambda_i - \nu_i = 0$. 此时取 $x =$

$\sum_{i=1}^m \lambda_i b_i a_i^T$ 得到最小值

$$\min_{x,\xi} L(x,\xi,\lambda,\nu) = -\frac{1}{2} \left\| \sum_{i=1}^m \lambda_i b_i a_i \right\|_2^2 + \sum_{i=1}^m \lambda_i,$$

由此对偶问题为

$$\begin{aligned} \max \quad & -\frac{1}{2} \left\| \sum_{i=1}^m \lambda_i b_i a_i \right\|_2^2 + \sum_{i=1}^m \lambda_i, \\ \text{s.t.} \quad & \lambda + \nu = \mu, \\ & \nu_i \geq 0, \quad \forall i = 1, 2, \dots, m, \\ & \lambda_i \geq 0, \quad \forall i = 1, 2, \dots, m. \end{aligned}$$

对 ν 进一步分析, 上述问题等价于

$$\begin{aligned} \max \quad & -\frac{1}{2} \left\| \sum_{i=1}^m \lambda_i b_i a_i \right\|_2^2 + \sum_{i=1}^m \lambda_i, \\ \text{s.t.} \quad & \lambda_i \leq \mu_i, \quad \forall i = 1, 2, \dots, m, \\ & \lambda_i \geq 0, \quad \forall i = 1, 2, \dots, m. \end{aligned}$$

□

4.14 考虑优化问题

$$\min_{x \in \mathbb{R}, y > 0} e^{-x}, \quad \text{s.t.} \quad \frac{x^2}{y} \leq 0.$$

(a) 证明这是一个凸优化问题, 求出最小值并判断 Slater 条件是否成立;

(b) 写出该问题的对偶问题, 并求出对偶问题的最优解以及对偶间隙.

解 (丁思哲).

(a) 设 $f(x, y) = e^{-x}$, 并有约束 $c(x, y) = \frac{x^2}{y} \leq 0$ 且 $y > 0$. 容易证明 $f(x, y)$ 和 $c(x, y)$ 均是凸函数 (用二阶条件), 因此该问题是凸优化问题.

在约束 $y > 0$ 的限制下, 显然 $x = 0$ 才能满足题意, 因此该问题的解是 $f(0, y) = 1$.

Slater 条件不成立. 因为取 x, y 为相对内点集中的值时, $c(x, y) < 0$ 与 $y > 0$ 无法同时满足.

(b) 先化简原问题. 由上一问的分析可知, 原问题等价于

$$\min_{x \in \mathbb{R}} e^{-x}, \quad \text{s.t. } x = 0,$$

因此引入乘子 v , 拉格朗日函数为

$$L(x, v) = e^{-x} + vx,$$

那么

$$g(v) = \inf_{x \in \mathbb{R}} \{e^{-x} + vx\} = \begin{cases} v - v \ln v, & v > 0, \\ -\infty, & v \leq 0. \end{cases}$$

因此对偶问题为

$$\max_{v \in \mathbb{R}} v - v \ln v, \quad \text{s.t. } v > 0,$$

显然其最优解在 $v = 1$ 时取得, 此时 $v - v \ln v = 1$, 对偶间隙为 0. \square

解 (邓展望). 首先写出该问题的拉格朗日函数:

$$L(Z, V, \mu, \lambda) = \|X - ZV\|_F^2 - \mu^T(V^T V - I_p)\mu - \lambda^T Z^T \mathbf{1} = 0,$$

其中 $\mu \in \mathbb{R}^p, \lambda \in \mathbb{R}^q$. 对 Z, V 求导可得:

$$-2XV^T + 2ZVV^T - \mathbf{1}\lambda^T = 0, \quad (4.3a)$$

$$-2Z^T X + 2Z^T ZV - 2V(\mu\mu^T) = 0, \quad (4.3b)$$

在 (4.3a) 右乘 V 再左乘 $\mathbf{1}$ 分别得:

$$-2X + 2ZV - \mathbf{1}\lambda^T V = 0, \quad (4.4a)$$

$$-2\mathbf{1}^T X - n\lambda^T V = 0, \quad (4.4b)$$

因此有

$$\lambda^T V = -\frac{2}{n}\mathbf{1}^T X,$$

带入到(4.4a)可得

$$ZV = X - \mathbf{1}\mathbf{1}^T \frac{X}{n}. \quad \square$$

注 4.1 Z, V 的解不唯一. 因为若 $QQ^T = I, Q \in \mathbb{R}^{q \times q}$, 则 $ZQQ^T V = ZV$. 令 $\hat{Z} = ZQ, \hat{Q} = Q^T V$, 函数值不变.

第五章 无约束优化算法

5.1 设 $f(x)$ 是连续可微函数, d^k 是一个下降方向, 且 $f(x)$ 在射线 $\{x^k + \alpha d^k \mid \alpha > 0\}$ 上有下界. 求证: 当 $0 < c_1 < c_2 < 1$ 时, 总是存在满足 Wolfe 准则 (6.1.4a) (6.1.4b) 的点. 并举一个反例说明当 $0 < c_2 < c_1 < 1$ 时, 满足 Wolfe 准则的点可能不存在.

解 (谢中林). 记 $\phi(\alpha) = f(x^k + \alpha d^k)$, 在 α 较小时, 由 $f(x)$ 连续可微知

$$\phi(\alpha) = f(x^k) + \alpha \nabla f(x^k)^T d^k + o(|\alpha|).$$

因为 $\phi(\alpha)$ 在 $\alpha > 0$ 时有下界, 且 $\nabla f(x^k)^T d^k < 0$, 当 α 充分大时

$$\phi(\alpha) > f(x^k) + \alpha c_1 \nabla f(x^k)^T d^k.$$

故集合

$$A_1 = \{\alpha \mid \phi(\alpha) > f(x^k) + \alpha c_1 \nabla f(x^k)^T d^k, \alpha > 0\}$$

非空. 而在 α 充分小时, 利用 $0 < c_1 < 1$ 及 $\nabla f(x^k)^T d^k < 0$ 得

$$\phi(\alpha) < f(x^k) + \alpha c_1 \nabla f(x^k)^T d^k.$$

于是集合 A_1 有下界.

记 $\xi_1 = \inf A_1$, 由 $f(x)$ 的连续性知 $\phi(\xi_1) = f(x^k) + \alpha c_1 \xi_1 \nabla f(x^k)^T d^k$. 借助拉格朗日中值定理知, 存在 $\zeta \in (0, \xi_1)$, 使得

$$\phi'(\zeta) = c_1 \nabla f(x^k)^T d^k \geq c_2 \nabla f(x^k)^T d^k,$$

$$\phi(\zeta) \leq f(x^k) + \alpha c_1 \nabla f(x^k)^T d^k.$$

□

5.2 f 为正定二次函数 $f(x) = \frac{1}{2}x^T Ax + b^T x$, d^k 为下降方向, x^k 为当前迭代点. 试求出精确线搜索步长

$$\alpha_k = \arg \min_{\alpha > 0} f(x^k + \alpha d^k),$$

并由此推出最速下降法的步长满足 (6.2.2) 式 (见定理 6.2).

解 (谢中林). 此时 $f(x^k + \alpha d^k)$ 关于 α 强凸, 由一阶条件知

$$\frac{d}{d\alpha} f(x^k + \alpha_k d^k) = \alpha_k (d^k)^T A d^k + (x^k)^T A d^k + b^T d^k = 0.$$

于是精确线搜索步长为

$$\alpha_k = -\frac{(x^k)^T A d^k + b^T d^k}{(d^k)^T A d^k} = -\frac{(Ax^k + b)^T d^k}{(d^k)^T A d^k}.$$

在最速下降法中, $d^k = -\nabla f(x^k) = -(Ax^k + b)$, 代入上式即得

$$\alpha_k = \frac{\|\nabla f(x^k)\|^2}{\nabla f(x^k)^T A \nabla f(x^k)}. \quad \square$$

5.3 利用定理 6.5 证明推论 6.2.

解 (谢中林). 已知

$$2 \left(\sum_{i=0}^k \alpha_i \right) (\hat{f}^k - f^*) \leq \|x^0 - x^*\|^2 + \sum_{i=0}^k \alpha_i^2 G^2.$$

(1) 取 $\alpha_i = t, \forall i$ 即得

$$\hat{f}^k - f^* \leq \frac{\|x^0 - x^*\|^2}{2(k+1)t} + \frac{G^2 t}{2}.$$

(2) 此时

$$\begin{aligned} \|x^{i+1} - x^*\|^2 &= \|x^i - \alpha_i g^i - x^*\|^2 \\ &= \|x^i - x^*\|^2 - 2\alpha_i \langle g^i, x^i - x^* \rangle + \alpha_i^2 \|g^i\|^2 \\ &\leq \|x^i - x^*\|^2 - 2\alpha_i (f(x^i) - f^*) + s^2. \end{aligned}$$

因此定理可改写为

$$2 \left(\sum_{i=0}^k \alpha_i \right) (\hat{f}^k - f^*) \leq \|x^0 - x^*\|^2 + (k+1)s^2.$$

又 $\sum_{i=0}^k \alpha_i \|g_i\| = (k+1)s \leq \sum_{i=0}^k \alpha_i G$, 因此 $(k+1)s/G \leq \sum_{i=0}^k \alpha_i$,
 则

$$\hat{f}^k - f^* \leq \frac{G \|x^0 - x^*\|^2}{2(k+1)s} + \frac{Gs}{2}.$$

(3) 同时除以 $2(\sum_{i=0}^k \alpha_i)$ 即得

$$\hat{f}^k - f^* \leq \frac{\|x^0 - x^*\|^2 + G^2 \sum_{i=0}^k \alpha_i^2}{2 \sum_{i=0}^k \alpha_i}. \quad \square$$

5.4 考虑非光滑函数

$$f(x) = \max_{1 \leq i \leq K} x_i + \frac{1}{2} \|x\|^2,$$

其中 $x \in \mathbb{R}^n$, $K \in [1, n]$ 为一个给定的正整数.

- (a) 求出 $f(x)$ 的最小值点 x^* 和对应的函数值 f^* ;
- (b) 证明 $f(x)$ 在区域 $\{x \mid \|x\| \leq R \stackrel{\text{def}}{=} 1/\sqrt{K}\}$ 上是 G -利普希茨连续的, 其中 $G = 1 + \frac{1}{\sqrt{K}}$;
- (c) 设初值 $x^0 = 0$, 考虑使用次梯度算法 (6.3.1) 对 $\min f(x)$ 进行求解, 其中 x 处的次梯度取为 $g = x + e_j$, j 为使得 $x_j = \max_{1 \leq i \leq K} x_i$ 成立的最小整数, 步长 α_k 可任意选取, 证明: 在 k ($k < K$) 次迭代后,

$$\hat{f}^k - f^* \geq \frac{GR}{2(1 + \sqrt{K})},$$

其中 \hat{f}^k 的定义和定理 6.5 相同. 并根据此例子推出次梯度算法的收敛速度 $\mathcal{O}\left(\frac{GR}{\sqrt{K}}\right)$ 是不能改进的.

解 (谢中林).

- (a) 引入辅助变量 t , 原问题等价于

$$\min_{x, t} t + \frac{1}{2} \|x\|^2, \quad \text{s.t. } x_i \leq t, \quad i = 1, 2, \dots, K.$$

设 $\lambda_i \geq 0$ 为 $x_i \leq t$ 对应的乘子, 其 KKT 条件为

$$\begin{aligned} x_i &= 0, \quad i = K+1, \dots, n, \\ x_i + \lambda_i &= 0, \quad \lambda_i(t - x_i) = 0, \quad i = 1, \dots, K, \\ t &\geq x_i, \quad \lambda_i \geq 0, \quad i = 1, \dots, K, \\ \sum_{i=1}^K \lambda_i &= 1. \end{aligned}$$

解得 $\sum_{i=1}^K x_i^2 = -t$, $t \geq -\frac{1}{K}$, 分析取等条件知最小值点为

$$x_i^* = -\frac{1}{K}, \quad i = 1, \dots, K; \quad x_i^* = 0, \quad i = K+1, \dots, n.$$

$$\text{最小值 } f^* = -\frac{1}{2K}.$$

(b) 由于

$$\max_{1 \leq i \leq K} x_i \leq \max_{1 \leq i \leq K} (x_i - y_i) + \max_{1 \leq i \leq K} y_i \leq \max_{1 \leq i \leq K} y_i + \|x - y\|_2,$$

因此当 $\|x\|$ 与 $\|y\|$ 小于等于 $1/\sqrt{K}$ 时,

$$f(x) - f(y) \leq \|x - y\|_2 + \frac{1}{2}(x + y)^T(x - y) \leq (1 + \frac{1}{\sqrt{K}})\|x - y\|_2.$$

(c) 由于 $x^0 = 0$, 根据次梯度的选取方式知 $g^0 = e_1$, 因此 x^1 的第 1 个元素小于 0, 其余元素仍为 0, 故 $g^1 = e_2$. 可以归纳地证明

$$x^k \in \text{span}\{e_1, \dots, e_k\}.$$

由于 $k < K$, 因此 x^k 的第 K 个元素为 0, 于是

$$f^k - f^* \geq x_K^k + \frac{1}{2}\|x^k\|^2 + \frac{1}{2(1+k)} \geq \frac{1}{2(1+k)} \geq \frac{GR}{2(1+\sqrt{k})}. \quad \square$$

5.5 考虑非平方 ℓ_2 正则项优化问题

$$\min \quad f(x) = \frac{1}{2}\|Ax - b\|_2^2 + \mu\|x\|_2,$$

其中 $A \in \mathbb{R}^{m \times n}$, 注意这个问题并不是岭回归问题.

(a) 若 A 为列正交矩阵, 即 $A^T A = I$, 利用不可微函数的一阶最优性条件求出该优化问题的显式解;

- (b) 对一般的 A 我们可以使用迭代算法来求解这个问题. 试设计出引入次梯度的一种梯度类算法求解该优化问题. 提示: $f(x)$ 仅在一点处不可导, 若这个点不是最小值点, 则次梯度算法和梯度法等价.

解 (谢中林).

- (a) 在 $\|A^T b\|_2 > \mu$ 时, 若 $A^T b \neq 0$, 在 $x \neq 0$ 时, 一阶最优性条件为

$$(1 + \frac{\mu}{\|x\|_2})x = A^T b.$$

这说明 x 与 $A^T b$ 共线. 假设 $x = \alpha A^T b$, 代入得

$$\alpha = 1 - \frac{\mu}{\|A^T b\|_2}, \quad x = \left(1 - \frac{\mu}{\|A^T b\|_2}\right) A^T b.$$

由凸性即知这是唯一的最小值点.

在 $\mu \geq \|A^T b\|_2$ 时, 利用柯西不等式得

$$f(x) = \frac{1}{2}\|b\|_2^2 + \frac{1}{2}\|Ax\|_2^2 + \mu\|x\|_2 - b^T Ax \geq \frac{1}{2}\|b\|_2^2 = f(0).$$

且等号可以在 $x = 0$ 处取到, 因此最小值点为 $x = 0$.

- (b) 仅需考虑 $\mu < \|A^T b\|_2$ 的情况. 构造 $g_\lambda(x) = f(\lambda x)$, 其中 $\lambda > 0$, 此时

$$g_\lambda(0) = \frac{1}{2}\|b\|_2^2.$$

任取 y 使得 $\mu\|y\|_2 - b^T Ay < 0$, 则

$$g_\lambda(y) = \frac{1}{2}\|b\|_2^2 + \frac{\|Ay\|_2^2}{2}\lambda^2 + (\mu\|y\|_2 - b^T Ay)\lambda.$$

利用二次函数的性质, 此时总存在 $\lambda > 0$ 使得 $g_\lambda(y) < g_\lambda(0)$. 于是 $x = 0$ 不是 $g_\lambda(x)$ 的最小值点.

由梯度法的下降性质, 以 y 为初始点的梯度法不会经过不可导的零点, 故利用梯度法求得 g_λ 的最小值点 y^* 后即得 f 的最小值点为 y^*/λ . \square

5.6 设函数 $f(x) = \|x\|^\beta$, 其中 $\beta > 0$ 为给定的常数. 考虑使用经典牛顿法 (6.4.2) 对 $f(x)$ 进行极小化, 初值 $x^0 \neq 0$. 证明:

- (a) 若 $\beta > 1$ 且 $\beta \neq 2$, 则 x^k 收敛到 0 的速度为 Q-线性的;
 (b) 若 $0 < \beta < 1$, 则牛顿法发散;
 (c) 试解释定理 6.6 在 (a) 中不成立的原因.

解 (谢中林).

- (a) 在 $x \neq 0$ 时, 牛顿方程为

$$(\|x\|^2 I + (\beta - 2)xx^T)d = -\|x\|^2 x.$$

分别在等式两边左乘 x^T 与 d^T 并化简得

$$x^T d = \frac{1}{1 - \beta} \|x\|^2, \quad \|d^T\|^2 = \frac{1}{(\beta - 1)^2} \|x\|^2.$$

由于 $\beta > 1$ 且 $\beta \neq 2$, 故

$$\frac{\|x + d\|^2}{\|x\|^2} = \frac{(\beta - 2)^2}{(\beta - 1)^2} < 1,$$

这说明此时牛顿法是 Q-线性收敛的.

- (b) 在 $0 < \beta < 1$ 时

$$\frac{\|x + d\|^2}{\|x\|^2} = \frac{(\beta - 2)^2}{(\beta - 1)^2} > 1,$$

牛顿法发散.

- (c) 函数 $f(x)$ 的海瑟矩阵为

$$\nabla^2 f(x) = \beta \|x\|^{\beta-2} I + \beta(\beta - 2) \|x\|^{\beta-4} xx^T.$$

在 $1 < \beta < 2$ 时, $\|x\|^{\beta-2}$ 在 $x = 0$ 附近不是利普希茨连续的, 不符合定理条件; 而在 $2 < \beta$ 时, $\|x\|^{\beta-4} xx^T$ 与 $\|x\|^{\beta-2} I$ 在 $x = 0$ 处极限均为 0, 即 $\nabla^2 f(x)$ 不正定, 也不符合定理条件.

□

5.7 设矩阵 A 为 n 阶对称矩阵, d^k 为给定的非零向量. 若对任意满足 $\|d\| = \|d^k\|$ 的 $d \in \mathbb{R}^n$, 均有 $(d - d^k)^T A(d - d^k) \geq 0$, 证明: A 是半正定矩阵.

解 (谢中林). 当 $x^T d^k \neq 0$ 时, 构造

$$d = d^k + \alpha x,$$

其中 $\alpha \neq 0$ 是待定系数. 令 $\|d\| = \|d^k\|$, 解得 $\alpha = -x^T d^k / \|x\|^2$. 于是

$$x^T A x = \frac{1}{\alpha^2} (d - d^k)^T A (d - d^k) \geq 0.$$

在 $x^T d^k = 0$ 时, 构造 $x^n = x + \frac{1}{n} d^k$, 则由连续性

$$x^T A x = \lim_{n \rightarrow \infty} (x^n)^T A x^n \geq 0.$$

综上, A 半正定. □

5.8 设 $f(x)$ 为正定二次函数, 且假定在迭代过程中 $(s^k - H^k y^k)^T y^k > 0$ 对任意的 k 均满足, 其中 H^k 由 SR1 公式 (6.5.10) 产生的拟牛顿矩阵. 证明:

$$H^k y^j = s^j, \quad j = 0, 1, \dots, k-1,$$

其中 k 是任意给定的整数. 这个结论说明对于正定二次函数, SR1 公式产生的拟牛顿矩阵在当前点处满足割线方程, 且历史迭代产生的 (s^j, y^j) 也满足割线方程.

解 (谢中林). 我们利用归纳法证明此结论. 设 $f(x) = \frac{1}{2} x^T Q x + b^T x$, 其中 $Q \succ 0$, 则在迭代过程中始终有 $Q s^j = y^j$. 假设结论对 k 成立, 即

$$H^k y^j = s^j, \quad j = 0, 1, \dots, k-1.$$

考虑 $k+1$ 时的情形, 由于

$$H^{k+1} = H^k + \frac{(s^k - H^k y^k)(s^k - H^k y^k)^T}{(s^k - H^k y^k)^T y^k},$$

故

$$H^{k+1} y^k = H^k y^k + s^k - H^k y^k = s^k.$$

当 $j \leq k-1$ 时, 利用归纳假设, 有

$$\begin{aligned}
 H^{k+1}y^j &= H^ky^j + \frac{(s^k - H^ky^k)((s^k)^T y^j - (y^k)^T H^ky^j)}{(s^k - H^ky^k)^T y^k} \\
 &= s^j + \frac{(s^k - H^ky^k)((s^k)^T y^j - (y^k)^T s^j)}{(s^k - H^ky^k)^T y^k} \quad \square \\
 &= s^j + \frac{(s^k - H^ky^k)(s^k)^T (Q - Q) s^j}{(s^k - H^ky^k)^T y^k} \\
 &= s^j.
 \end{aligned}$$

5.9 仿照 BFGS 公式的推导过程, 利用待定系数法推导 DFP 公式 (6.5.15).

解 (谢中林). 假设

$$H^{k+1} = H^k + auu^T + bvv^T.$$

由割线方程得

$$H^{k+1}y^k = H^ky^k + (au^T y^k)u + (bv^T y^k)v = s^k,$$

令 $u = H^ky^k, v = s^k$, 并令系数 $au^T y^k = -1, bv^T y^k = 1$ 即得

$$H^{k+1} = H^k - \frac{H^ky^k (H^ky^k)^T}{(y^k)^T H^ky^k} + \frac{s^k (s^k)^T}{(y^k)^T s^k}. \quad \square$$

5.10 (小样本问题) 设 $J(x) \in \mathbb{R}^{m \times n}$ 为最小二乘问题 (6.7.1) 中 $r(x)$ 在点 x 处的雅可比矩阵, 其中 $m \ll n$. 设 $J(x)$ 行满秩, 证明:

$$\hat{d} = -J(x)^T (J(x)J(x)^T)^{-1} r(x)$$

给出了高斯 - 牛顿方程 (6.7.3) 的一个 ℓ_2 范数最小解.

解 (谢中林). 假设 d 也是高斯 - 牛顿方程的解, 则

$$\|d\|^2 = \|d - \hat{d}\|^2 + 2(d - \hat{d})^T \hat{d} + \|\hat{d}\|^2.$$

由于 $J^T J d = -J^T r$, 因此 $J^T J (d - \hat{d}) = 0$, 由 J 行满秩得 $J(d - \hat{d}) = 0$, 故 $(d - \hat{d})^T \hat{d} = 0$, 于是

$$\|d\|^2 \geq \|d - \hat{d}\|^2 + \|\hat{d}\|^2 \geq \|\hat{d}\|^2. \quad \square$$

第六章 约束优化算法

6.1 构造一个等式约束优化问题，使得它存在一个局部极小值，但对于任意的 $\sigma > 0$ ，它的二次罚函数是无界的。

解 (谢中林). 考虑

$$\min_{x,y} -e^x, \quad \text{s.t. } x^2 + y^2 = 1.$$

其局部最小值点为 $(1, 0)$ ，但对任意的 $\sigma > 0$ ，二次罚函数

$$P_E(x, y, \sigma) = -e^x + \frac{\sigma}{2}(x^2 + y^2 - 1)^2$$

无下界. □

6.2 考虑等式约束优化问题

$$\begin{aligned} \min \quad & -x_1 x_2 x_3, \\ \text{s.t.} \quad & x_1 + 2x_2 + 3x_3 = 60. \end{aligned}$$

使用二次罚函数求解该问题，当固定罚因子 σ_k 时，写出二次罚函数的最优解 x^{k+1} 。当 $\sigma_k \rightarrow +\infty$ 时，写出该优化问题的解并求出约束的拉格朗日乘子。此外，当罚因子 σ 满足什么条件时，二次罚函数的海瑟矩阵 $\nabla_{xx}^2 P_E(x, \sigma)$ 是正定的？

解 (谢中林). 该问题的二次罚函数为

$$P_E(x, \sigma) = -x_1 x_2 x_3 + \frac{\sigma}{2}(x_1 + 2x_2 + 3x_3 - 60)^2.$$

利用一阶最优性条件得

$$x_2 x_3 = \frac{x_3 x_1}{2} = \frac{x_1 x_2}{3}.$$

由于 $x = (10, 10, 10)^T$ 时 $P_E(x, \sigma) = -1000 < 0$, 而当 x_i 中存在 0 时最小值必大于 0, 因此最小值点坐标全部非 0, 此时 $2x_2 = x_1, 3x_3 = x_1$, 最优性条件等价于

$$-x_1^2 + 18\sigma(x_1 - 20) = 0,$$

故仅在 $81\sigma^2 - 360\sigma > 0$ 时有极小值点, 解得

$$\begin{aligned} x_1(\sigma) &= 9\sigma - \sqrt{81\sigma^2 - 360\sigma}, \\ x_2(\sigma) &= \frac{1}{2}x_1(\sigma), \quad x_3(\sigma) = \frac{1}{3}x_1(\sigma). \end{aligned}$$

于是在 $\sigma \rightarrow \infty$ 时,

$$x_1 = \lim_{\sigma \rightarrow \infty} \frac{360\sigma}{9\sigma + \sqrt{81\sigma^2 - 360\sigma}} = 20, \quad x_2 = 10, \quad x_3 = \frac{20}{3}.$$

利用 (7.1.5) 式, 拉格朗日乘子为

$$\begin{aligned} \lambda &= - \lim_{\sigma \rightarrow \infty} \sigma(x_1(\sigma) + 2x_2(\sigma) + 3x_3(\sigma) - 60) \\ &= -60 \lim_{\sigma \rightarrow \infty} \sigma \left(\frac{6\sigma}{3\sigma + \sqrt{9\sigma^2 - 40\sigma}} - 1 \right) \\ &= -60 \lim_{\sigma \rightarrow \infty} \frac{40\sigma^2}{(3\sigma + \sqrt{9\sigma^2 - 40\sigma})^2} \\ &= -\frac{200}{3}. \end{aligned}$$

由

$$\nabla_{xx}^2 P_E(x, \sigma) = \sigma \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \begin{bmatrix} 1 & 2 & 3 \end{bmatrix} - \begin{bmatrix} 0 & x_3 & x_2 \\ x_3 & 0 & x_1 \\ x_2 & x_1 & 0 \end{bmatrix},$$

应该考虑 $\nabla_{xx}^2 P_E(x(\sigma), \sigma)$ 的正定性以确定罚因子的值. □

6.3 考虑等式约束优化问题

$$\min f(x), \quad \text{s.t.} \quad c_i(x) = 0, \quad i \in \mathcal{E},$$

定义一般形式的罚函数

$$P_E(x, \sigma) = f(x) + \sigma \sum_{i \in \mathcal{E}} \varphi(c_i(x)),$$

其中 $\varphi(t)$ 是充分光滑的函数, 且 $t=0$ 是其 s 阶零点 ($s \geq 2$), 即

$$\varphi(0) = \varphi'(0) = \cdots = \varphi^{(s-1)}(0) = 0, \quad \varphi^{(s)}(0) \neq 0.$$

设 x^k, σ_k 的选取方式和算法 7.1 的相同, 且 $\{x^k\}$ 存在极限 x^* , 在点 x^* 处 LICQ (见定义 5.9) 成立.

- (a) 证明: $\sigma_k(c_i(x^k))^{s-1}, \forall i \in \mathcal{E}$ 极限存在, 其极限 λ_i^* 为约束 $c_i(x^*) = 0$ 对应的拉格朗日乘子;
- (b) 求 $P_E(x, \sigma)$ 关于 x 的海瑟矩阵 $\nabla_{xx}^2 P_E(x, \sigma)$;
- (c) 设在 (a) 中 $\lambda_i^* \neq 0, \forall i \in \mathcal{E}$, 证明: 当 $\sigma_k \rightarrow +\infty$ 时, $\nabla_{xx}^2 P_E(x^k, \sigma_k)$ 有 m 个特征值的模长与 $\sigma_k^{1/(s-1)}$ 同阶, 其中 $m = |\mathcal{E}|$.

解 (陈铖, 丁思哲).

- (a) 利用定理 7.2, 首先求 $P_E(x, \sigma)$ 的一阶梯度, 即

$$\nabla_x P_E(x, \sigma) = \nabla_x f(x) + \sigma \sum_{i \in \mathcal{E}} \varphi'(c_i(x)) \nabla_x c_i(x),$$

因此由 $\varphi'(0) = 0$ 得

$$\|\nabla_x P_E(x^{k+1}, \sigma_k)\| \rightarrow 0,$$

结合题设和定理 7.2 可知 x^* 是问题的 KKT 点, 且

$$\lambda_i^* = \lim_{k \rightarrow \infty} (\sigma_k \varphi'(c_i(x^{k+1}))),$$

其中 λ_i^* 是约束 $c_i(x^*) = 0$ 对应的拉格朗日乘子.

若迭代点收敛到最优解, 则 $k \rightarrow \infty$ 时, $c_i(x^{k+1}) \rightarrow 0$, 即逐渐满足等式约束. 由于 $c_i(x)$ 连续且 $\varphi(t)$ 充分光滑, 可将 $\varphi'(c_i(x^{k+1}))$ 在 $c_i(x^*) = 0$ 处泰勒展开, 因此

$$\begin{aligned} \lim_{k \rightarrow \infty} (\sigma_k \varphi'(c_i(x^{k+1}))) &= \lim_{k \rightarrow \infty} \left(\frac{1}{s!} \sigma_k \varphi^{(s)}(c_i(x^{k+1})) (c_i(x^{k+1}))^{s-1} \right) \\ &= \frac{1}{s!} \varphi^{(s)}(0) \lim_{k \rightarrow \infty} (\sigma_k (c_i(x^{k+1}))^{s-1}). \end{aligned}$$

- (b) 直接对 $\nabla_x P_E(x, \sigma)$ 中的 x 微分, 得海瑟矩阵为

$$\begin{aligned} \nabla_{xx}^2 P_E(x, \sigma) &= \nabla_{xx}^2 f(x) + \sigma \sum_{i \in \mathcal{E}} \varphi'(c_i(x)) \nabla_{xx}^2 c_i(x) \\ &\quad + \sigma \sum_{i \in \mathcal{E}} \varphi''(c_i(x)) \nabla_x c_i(x) \nabla_x c_i(x)^T. \end{aligned}$$

(c) 同 (7.1.11) 式, 在 k 较大时 ($x^{k+1} \approx x^*$), 上述海瑟矩阵的前 2 项可以用拉格朗日函数近似. 此时对于 x^{k+1} , 成立近似

$$\begin{aligned} \nabla_{xx}^2 P_E(x^{k+1}, \sigma_k) &\approx \nabla_{xx}^2 L(x^{k+1}, \lambda^*) \\ &\quad + \sigma_k \sum_{i \in \mathcal{E}} \varphi''(c_i(x^{k+1})) \nabla_x c(x^{k+1}) \nabla_x c(x^{k+1})^T, \end{aligned}$$

其中 $c(x) = [c_i(x)]_{i \in \mathcal{E}}$. 由于 $\nabla_x c(x^{k+1}) \nabla_x c(x^{k+1})^T$ 是半正定矩阵, 它有 $(n-m)$ 个特征值都是 0, 不妨设所有非 0 的特征值为 $\{\rho_j\}_{j=1}^m$, 它们与 σ_k 无关.

$\nabla_{xx}^2 L(x, \lambda^*)$ 是定值矩阵, 而海瑟矩阵的另一项是一个最大特征值趋近于正无穷的矩阵. 因此当 $k \rightarrow \infty$ 时, 可以在阶数意义上忽略定值矩阵的特征值.

综上, k 足够大时, 海瑟矩阵的特征值趋近于 $\{\rho_j \sigma_k \varphi''(c_i(x^{k+1}))\}$. 再对 $\varphi''(c_i(x^{k+1}))$ 在 $c_i(x^*) = 0$ 处做泰勒近似, 展开到 s 阶, 成立

$$\begin{aligned} \lim_{k \rightarrow \infty} \frac{\rho_i \sigma_k \varphi''(c_i(x^{k+1}))}{\sigma_k^{1/(s-1)}} &= \lim_{k \rightarrow \infty} \frac{\rho_i \sigma_k \varphi^{(s)}(c_i(x^{k+1}))(c_i(x^{k+1}))^{s-2}}{(s-2)! \sigma_k^{1/(s-1)}} \\ &= \lim_{k \rightarrow \infty} \frac{\varphi^{(s)}(c_i(x^{k+1}))(\sigma_k(c_i(x^{k+1})))^{s-1}}{(s-2)!}^{\frac{s-2}{s-1}} \\ &= \frac{\varphi^{(s)}(0)}{(s-2)!} \lim_{k \rightarrow \infty} (\sigma_k(c_i(x^{k+1})))^{s-1}^{\frac{s-2}{s-1}}. \end{aligned}$$

由 (a) 知 $\sigma_k(c_i(x^{k+1}))^{s-1}$ 存在, 再由题设知其非 0, 因此 $k \rightarrow \infty$ 时海瑟矩阵的特征值与 $\sigma_k^{1/(s-1)}$ 同阶. \square

6.4 考虑不等式约束优化问题 (7.1.2), 其中 f 在可行域 \mathcal{X} 上有下界, 现使用对数罚函数法进行求解 (算法 7.4). 假设在算法 7.4 的每一步子问题能求出罚函数的全局极小值点 x^{k+1} , 证明: 算法 7.4 在有限次迭代后终止, 或者

$$\lim_{k \rightarrow \infty} c_k \sum_{i \in \mathcal{I}} \ln(-c_i(x^{k+1})) = 0,$$

并且

$$\lim_{k \rightarrow \infty} f(x^k) = \inf_{x \in \text{int } \mathcal{X}} f(x).$$

解 (谢中林). 若算法不能在有限步终止, 任取 $\eta > 0$, 存在 $x_\eta \in \mathbf{int}\mathcal{X}$, 使得

$$f(x_\eta) < \inf_{x \in \mathbf{int}\mathcal{X}} f(x) + \frac{\eta}{2}.$$

由算法不能在有限步终止知 $\sigma_k \rightarrow 0$, 故存在 \bar{k} , 使得任取 $k > \bar{k}$, 有

$$\frac{1}{\sigma_k} > \frac{2}{\eta} \sum_{i \in \mathcal{I}} \ln(-c_i(x_\eta)).$$

由 x_{k+1} 的定义, 有

$$P_I(x_{k+1}, \sigma_k) \leq P_I(x_\eta, \sigma_k).$$

于是任取 $k > \bar{k}$, 有

$$\begin{aligned} \sigma_k \sum_{i \in \mathcal{I}} \ln(-c_i(x_{k+1})) &\leq f(x_\eta) + \sigma_k \sum_{i \in \mathcal{I}} \ln(-c_i(x_\eta)) - f(x_{k+1}) \\ &\leq \inf_{x \in \mathbf{int}\mathcal{X}} f(x) + \frac{1}{2}\eta + \frac{1}{2}\eta - f(x_{k+1}) \\ &\leq \eta, \end{aligned}$$

由 η 的任意性知

$$\lim_{k \rightarrow \infty} c_k \sum_{i \in \mathcal{I}} \ln(-c_i(x^{k+1})) = 0.$$

同理可得任取 $k > \bar{k}$, 有

$$\begin{aligned} f(x_{k+1}) &\leq f(x_\eta) + \sigma_k \sum_{i \in \mathcal{I}} \ln(-c_i(x_\eta)) \\ &\leq \inf_{x \in \mathbf{int}\mathcal{X}} f(x) + \eta. \end{aligned}$$

由 η 的任意性知

$$\lim_{k \rightarrow \infty} f(x^k) = \inf_{x \in \mathbf{int}\mathcal{X}} f(x). \quad \square$$

6.5 考虑一般约束优化问题 (7.1.15), 现在针对等式约束使用二次罚函数, 对不等式约束使用对数罚函数:

$$P(x, \sigma) = f(x) + \frac{\sigma}{2} \sum_{i \in \mathcal{E}} c_i^2(x) - \frac{1}{\sigma} \sum_{i \in \mathcal{I}} \ln(-c_i(x)),$$

其中 $\mathbf{dom} P = \{x \mid c_i(x) < 0, i \in \mathcal{I}\}$. 令罚因子 $\sigma_k \rightarrow +\infty$, 定义

$$x^{k+1} = \arg \min_x P(x, \sigma_k).$$

假定涉及的所有函数都是连续的, $\{x \mid c_i(x) \leq 0, i \in \mathcal{I}\}$ 是有界闭集, x^* 为问题 (7.1.15) 的解. 试证明如下结论:

- (a) $\lim_{k \rightarrow \infty} P(x^{k+1}, \sigma_k) = f(x^*);$
- (b) $\lim_{k \rightarrow \infty} \sigma_k \sum_{i \in \mathcal{E}} c_i^2(x^{k+1}) = 0;$
- (c) $\lim_{k \rightarrow \infty} \frac{1}{\sigma_k} \sum_{i \in \mathcal{I}} \ln(-c_i(x^{k+1})) = 0.$

解 (陈铨、丁思哲). (a) 我们首先考虑将二次罚函数系数固定为 μ , 并将添加了二次罚函数的函数视作一个新的函数

$$g_\mu(x) = f(x) + \frac{\mu}{2} \sum_{i \in \mathcal{E}} c_i^2(x).$$

构造对于 $g_\mu(x)$ 的对数罚函数形式

$$\tilde{P}_\mu(x, \sigma) = g_\mu(x) - \frac{1}{\sigma} \sum_{i \in \mathcal{I}} \ln(-c_i(x)).$$

由前述证明知, $\sigma \rightarrow \infty$ 时, 对数罚函数法收敛到函数的最优值, 即

$$\lim_{k \rightarrow \infty} \tilde{P}_\mu(x_\mu^{k+1}, \sigma_k) = g_\mu(x_\mu^*).$$

其中 x_μ^* 是满足不等式约束的极小值点. 我们知道, 任取 μ , 当 $\sigma \leq \mu$ 时, 有

$$g_\mu(x) \geq f(x) + \frac{\sigma}{2} \sum_{i \in \mathcal{E}} c_i^2(x),$$

在添加对数罚函数之后, 不等式仍然成立, 即可得到

$$\tilde{P}_\mu(x, \sigma^k) \geq P(x, \sigma^k).$$

对左右两边取极小, 即可得到

$$\tilde{P}_\mu(x_\mu^{k+1}, \sigma^k) = \inf_x \tilde{P}_\mu(x, \sigma^k) \geq \inf_x P(x, \sigma^k) = P(x^{k+1}, \sigma^k).$$

由此

$$\lim_{k \rightarrow \infty} P(x^{k+1}, \sigma_k) \leq \lim_{k \rightarrow \infty} \tilde{P}_\mu(x_\mu^{k+1}, \sigma_k) = g_\mu(x_\mu^*).$$

上式对于任意 μ 均成立, 则有

$$\lim_{k \rightarrow \infty} P(x^{k+1}, \sigma_k) \leq \lim_{\mu \rightarrow 0} g_\mu(x_\mu^*).$$

注意到 $g_\mu(x_\mu^*)$ 是在满足不等式约束的条件下 $g_\mu(x)$ 的极小值, 如果将定义域设置为满足不等式约束的所有点, 则 x_μ^* 是 $g_\mu(x)$ 在定义域上的极小值, 而 $g_\mu(x)$ 是 $f(x)$ 的系数为 μ 的二次罚函数形式. 因此根据二次罚函数的收敛性, 我们有 $\lim_{\mu \rightarrow 0} g_\mu(x_\mu^*) = f(x^*)$, x^* 是定义域上满足等式约束的最小值, 即同时满足不等式约束以及等式约束的最小值.

同时, 我们知道 $\lim_{k \rightarrow \infty} P(x^{k+1}, \sigma_k) \geq f(x^*)$.

综上所述可得

$$f(x^*) \leq \lim_{k \rightarrow \infty} P(x^{k+1}, \sigma_k) \leq f(x^*),$$

即 $\lim_{k \rightarrow \infty} P(x^{k+1}, \sigma_k) = f(x^*)$.

(b) 根据 (a) 的说法, 对数罚函数法使得

$$\tilde{P}_\mu(x_\mu^{k+1}, \sigma^k) \rightarrow g_\mu(x_\mu^*),$$

在上式中使得 $\mu \rightarrow 0$, 即有

$$f(x^{k+1}) - \frac{1}{\sigma_k} \sum_{i \in \mathcal{E}} \ln(-c_i(x^{k+1})) \rightarrow f(x^*),$$

再联立 (a) 中证明的结论, 即有

$$\lim_{k \rightarrow \infty} \sigma_k \sum_{i \in \mathcal{E}} c_i^2(x^{k+1}) = 0.$$

(c) 固定对数罚函数的系数为 μ , 即设

$$h_\mu(x) = f(x) - \frac{1}{\mu} \sum_{i \in \mathcal{I}} \ln(-c_i(x)),$$

并在 $\text{dom } P$ 中讨论 $h_\mu(x)$. 构造对于 $h_\mu(x)$ 的二次罚函数形式, 类似 (a)(b) 讨论, 亦可得 $\lim_{k \rightarrow \infty} \frac{1}{\sigma_k} \sum_{i \in \mathcal{I}} \ln(-c_i(x^{k+1})) = 0$, 不再赘述. \square

6.6 (Morrison 方法) 考虑等式约束优化问题 (7.1.1), 设其最优解为 x^* . 令 M 是最优函数值 $f(x^*)$ 的一个下界估计 (即 $M \leq f(x^*)$), 构造辅助

函数

$$v(M, x) = [f(x) - M]^2 + \sum_{i \in \mathcal{E}} c_i^2(x),$$

Morrison 方法的迭代步骤如下:

$$\begin{aligned} x^k &= \arg \min_x v(M_k, x), \\ M_{k+1} &= M_k + \sqrt{v(M_k, x^k)}. \end{aligned}$$

试回答以下问题:

- (a) 证明: $f(x^k) \leq f(x^*)$;
- (b) 若 $M_k \leq f(x^*)$, 证明: $M_{k+1} \leq f(x^*)$;
- (c) 证明: $\lim_{k \rightarrow \infty} M_k = f(x^*)$;
- (d) 求 $v(M, x)$ 关于 x 的海瑟矩阵, 并说明 Morrison 方法和算法 7.1 的联系.

解 (丁思哲).

- (a) 用反证法. 若 $f(x^k) > f(x^*)$, 则有

$$v(M, x^*) < v(M, x^k),$$

这与题设矛盾. 因此, $f(x^k) \leq f(x^*)$.

- (b) 由于 $v(M_k, x^k) \leq v(M_k, x^*)$, 故有

$$\begin{aligned} M_{k+1} &= M_k + \sqrt{v(M_k, x^k)} \leq M_k + \sqrt{v(M_k, x^*)} \\ &= M_k + |f(x^*) - M_k|, \end{aligned}$$

而 $f(x^*) \geq M_k$, 则 $M_{k+1} \leq M_k + f(x^*) - M_k = f(x^*)$.

- (c) 考虑 Morrison 方法中 $x^k \rightarrow x^*$ ($k \rightarrow \infty$), 则

$$\begin{aligned} M_{k+1} &= M_k + \sqrt{v(M_k, x^k)} \\ &= M_k + \sqrt{(f(x^k) - M_k)^2 + \sum_{i \in \mathcal{E}} c_i^2(x^k)}. \end{aligned}$$

$\exists N \in \mathbb{N}_+$, 当 $\forall n \geq N$ 时, 成立

$$\begin{aligned} M_{n+1} &= M_n + \sqrt{(f(x^n) - M_n)^2 + \varepsilon_n} \\ &\leq M_n + |f(x^n) - M_n| + \varepsilon_n, \end{aligned}$$

其中 $\varepsilon_n > 0$ 且 $n \rightarrow \infty$ 时 $\varepsilon_n \rightarrow 0$.

同理, $M_{n+1} \geq M_n + |f(x^n) - M_n| - \varepsilon_n$.

令 $n \rightarrow \infty$, 且注意 $f(x^n) \rightarrow f(x^*)$, 则有

$$\lim_{k \rightarrow \infty} M_{k+1} = \lim_{k \rightarrow \infty} M_k = f(x^*).$$

(d) 经过简单的计算可知, 海瑟矩阵的 (i, j) 元为

$$2 \frac{\partial f}{\partial x_i} \frac{\partial f}{\partial x_j} + 2(f - M) \frac{\partial^2 f}{\partial x_i \partial x_j} + 2 \sum_{k \in \mathcal{E}} \frac{\partial c_k}{\partial x_i} \frac{\partial c_k}{\partial x_j} + 2 \sum_{k \in \mathcal{E}} c_k \frac{\partial^2 c_k}{\partial x_i \partial x_j}.$$

它与算法 7.1 的联系是, Morrison 方法仍为惩罚方法, 这与算法 7.1 所属的方法类别一致.

算法 7.1 通过调节惩罚项 $\sum_{i \in \mathcal{E}} c_i^2(x)$ 的权系数 σ_k 的大小施加惩罚, 而 Morrison 方法是一类惩罚项自适应的方法, 通过构造问题

$$\min_x v(M_k, x)$$

以使 $\sum_{i \in \mathcal{E}} c_i^2(x)$ 不断减小, 最终完成优化.

从分析的角度看, 将 Morrison 方法进一步写成

$$\begin{aligned} x^{k+1} = \arg \min_x \{ & f(x)[f(x) - 2M_k - 2\sqrt{v(M_k, x^k)}] + 2 \sum_{i \in \mathcal{E}} c_i^2(x) \} \\ & + M_k^2 + (f(x^k) - M_k)^2 + 2M_k \sqrt{v(M_k, x^k)}. \end{aligned}$$

由 (a), (c) 可得 $k \rightarrow \infty$ 时成立

$$\begin{aligned} \text{上式} &= f(x)(f(x) - 2f(x^*)) + 2 \sum_{i \in \mathcal{E}} c_i^2(x) + f^2(x^*) \\ &= (f(x) - f(x^*))^2 + 2 \sum_{i \in \mathcal{E}} c_i^2(x), \end{aligned}$$

因此 Morrison 方法在 k 足够大时, 相当于对问题

$$\min_x \{|f(x) - f(x^*)|^2 + 2 \sum_{i \in \mathcal{E}} c_i^2(x)\}$$

求解.

所以, 相比算法 7.1, Morrison 方法在运行后期的表现等同于将对 $f(x)$ 的优化换成对 $|f(x) - f(x^*)|^2$ 的优化, 而直接取 $\sigma_k = 4$. \square

6.7 考虑不等式约束优化问题

$$\min f(x), \quad \text{s.t.} \quad c_i(x) \leq 0, \quad i \in \mathcal{I}.$$

(a) 定义函数 $F(x) = \sup_{\lambda_i \geq 0} \left\{ f(x) + \sum_{i \in \mathcal{I}} \lambda_i c_i(x) \right\}$, 证明: 原问题等价于无约束优化问题 $\min_x F(x)$;

(b) 定义函数

$$\hat{F}(x, \lambda^k, \sigma_k) = \sup_{\lambda_i \geq 0} \left\{ f(x) + \sum_{i \in \mathcal{I}} \lambda_i c_i(x) - \frac{\sigma_k}{2} \sum_{i \in \mathcal{I}} (\lambda_i - \lambda_i^k)^2 \right\},$$

求 $\hat{F}(x, \lambda^k, \sigma_k)$ 的显式表达式;

(c) 考虑如下优化算法:

$$\begin{aligned} x^k &= \arg \min_x \hat{F}(x, \lambda^k, \sigma_k), \\ \lambda^{k+1} &= \arg \max_{\lambda \geq 0} \left\{ \sum_{i \in \mathcal{I}} \lambda_i c_i(x^k) - \frac{\sigma_k}{2} \sum_{i \in \mathcal{I}} (\lambda_i - \lambda_i^k)^2 \right\}, \\ \sigma_{k+1} &= \min\{\rho \sigma_k, \bar{\sigma}\}, \end{aligned}$$

试说明其与算法 7.5 的区别和联系.

解 (丁思哲). (a) 此证明实际上是“广义拉格朗日函数的极小极大问题与原问题等价”.

原问题的广义拉格朗日函数为

$$L(x, \lambda) = f(x) + \sum_{i \in \mathcal{I}} \lambda_i c_i(x), \quad \lambda_i \geq 0.$$

考虑关于 x 的函数

$$\begin{aligned} F(x) &= \sup_{\lambda_i \geq 0} L(x, \lambda) \\ &= \sup_{\lambda_i \geq 0} \left\{ f(x) + \sum_{i \in \mathcal{I}} \lambda_i c_i(x) \right\}, \end{aligned}$$

假设对某 x , 若 x 违反约束, 即 $\exists i \in \mathcal{I}$, 使 $c_i(x) > 0$, 则有

$$F(x) = \sup_{\lambda_i \geq 0} L(x, \lambda) \rightarrow \infty,$$

即 $F(x)$ 无定义. 相反, 若 x 不违反约束, 则 $F(x) < \infty$, 且取得 $\lambda_i = 0$.

因此,

$$\begin{aligned} \min_x F(x) &= \min_x \sup_{\lambda_i \geq 0} \left\{ f(x) + \sum_{i \in \mathcal{I}} \lambda_i c_i(x) \right\} \\ &= \min_x f(x) \quad \text{s.t.} \quad c_i(x) \leq 0 \quad (i \in \mathcal{I}). \end{aligned}$$

这就说明问题彼此是等价的.

(b) 适当取 λ_i 的值, 使得 $\hat{F}(x, \lambda^k, \sigma_k)$ 取极小值, 由极小性原理,

$$\lambda_i = \frac{c_i(x)}{\sigma_k} + \lambda_i^k \quad (\sigma_k \neq 0). \quad (6.1)$$

对于(6.1)所定义的 λ_i , 若 $\lambda_i \geq 0$, 则 $\hat{F}(x, \lambda^k, \sigma_k)$ 的显式表达式为

$$\begin{aligned} \hat{F}(x, \lambda^k, \sigma_k) &= f(x) + \sum_{i \in \mathcal{I}} \left(\frac{c_i(x)}{\sigma_k} + \lambda_i^k \right) c_i(x) - \frac{\sigma_k}{2} \sum_{i \in \mathcal{I}} \left(\frac{c_i(x)}{\sigma_k} \right)^2 \\ &= f(x) + \frac{1}{2} \sum_{i \in \mathcal{I}} \left(\frac{c_i^2(x)}{\sigma_k} + 2\lambda_i^k c_i(x) \right). \end{aligned}$$

否则, 需将 λ_i 的表达式

$$\lambda_i = \begin{cases} \frac{c_i(x)}{\sigma_k} + \lambda_i^k, & \frac{c_i(x)}{\sigma_k} + \lambda_i^k \geq 0 \\ 0, & \text{其它} \end{cases}$$

代入 $\hat{F}(x, \lambda^k, \sigma_k)$, 不再赘述.

(c) 本题的迭代格式为

$$\begin{aligned} x^{k+1} &= \arg \min_x \left\{ f(x) + \sum_{i \in \mathcal{I}} \lambda_i^k c_i(x) + \frac{1}{2\sigma_k} \sum_{i \in \mathcal{I}} c_i^2(x) \right\}, \\ \lambda^{k+1} &= \lambda^k + \frac{c(x^{k+1})}{\sigma_k}, \\ \sigma_{k+1} &= \min \{ \rho \sigma_k, \bar{\sigma} \}. \end{aligned}$$

对比算法 7.5, 本题迭代格式中的 $1/\sigma_k$ 对应与算法 7.5 中的 σ_k , 因此算法本质上是一样的. 只是, 本题的迭代格式中, σ_k 越小 (趋于 0) 则惩罚强度越大, 而算法 7.5 中的情况则恰相反. \square

6.8 对于 LASSO 问题

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} \|Ax - b\|_2^2 + \mu \|x\|_1,$$

写出该问题及其对偶问题的增广拉格朗日函数法.

解 (丁思哲).

LASSO 问题的增广拉格朗日函数法方法

LASSO 问题为

$$\min_x \frac{1}{2} \|Ax - b\|_2^2 + \mu \|x\|_1,$$

设 $z \in \mathbb{R}^n$, 将 LASSO 问题等价地写为

$$\begin{aligned} \min_x \quad & \frac{1}{2} \|z - b\|_2^2 + \mu \|x\|_1, \\ \text{s.t.} \quad & Ax - z = 0. \end{aligned}$$

上式的拉格朗日函数为

$$L(x, z, \lambda) = \frac{1}{2} \|z - b\|_2^2 + \mu \|x\|_1 + \lambda^T (Ax - z),$$

则其增广拉格朗日函数为

$$L_\sigma(x, z, \lambda) = \frac{1}{2} \|z - b\|_2^2 + \mu \|x\|_1 + \lambda^T (Ax - z) + \frac{1}{2} \sigma \|Ax - z\|_2^2.$$

因此, 增广拉格朗日函数法迭代求解的基本框架为

$$(x^{k+1}, z^{k+1}) = \operatorname{argmin}_{x, z} \{L_{\sigma_k}(x, z, \lambda^k)\}, \quad (6.2a)$$

$$\lambda^{k+1} = \lambda^k + \sigma_k (Ax^{k+1} - z^{k+1}), \quad (6.2b)$$

$$\sigma_{k+1} = \rho \sigma_k, \quad \sigma_k \uparrow \sigma_\infty < \infty. \quad (6.2c)$$

其中 (6.2a) 是求解最困难的地方. 除了利用投影梯度法或半光滑牛顿法联合变量求解 (x^{k+1}, z^{k+1}) 以外, 还可以利用最优性条件, 将 z 用 x 来表示, 进而可以只求关于 x 的问题.

(6.2a) 式中, 关于 z 的极小化问题为

$$\min_z \|z - b\|_2^2 + \sigma \left\| Ax - z + \frac{\lambda}{\sigma} \right\|_2^2,$$

则解得 $z = \frac{1}{\sigma + 1} (\sigma Ax + \lambda + b)$, 将 z 的表达式代入 (6.2a) 式, 可得

$$x^{k+1} = \arg \min_x \{L_{\sigma_k}(x; \lambda^k)\}.$$

LASSO 问题的对偶问题的增广拉格朗日函数法方法

先求 LASSO 问题的对偶问题. LASSO 问题的对偶函数为

$$\begin{aligned} g(y) &= \inf_{x,z} L(x, z, \lambda) \\ &= \inf_x \{ \mu \|x\|_1 + \lambda^T Ax \} + \inf_z \left\{ \frac{1}{2} \|z - b\|_2^2 - \lambda^T z \right\}. \end{aligned}$$

而

$$\begin{aligned} \inf_x \{ \mu \|x\|_1 + \lambda^T Ax \} &= \begin{cases} 0, & \|A^T \lambda\|_\infty \leq \mu, \\ -\infty, & \text{其它}. \end{cases} \\ \inf_z \left\{ \frac{1}{2} \|z - b\|_2^2 - \lambda^T z \right\} &= -\lambda^T b - \frac{1}{2} \|\lambda\|_2^2. \end{aligned}$$

则对偶问题为

$$\begin{aligned} \max_x \quad & -\frac{1}{2} \|\lambda\|_2^2 - \lambda^T b, \\ \text{s.t.} \quad & \|A^T \lambda\|_\infty \leq \mu. \end{aligned}$$

引入变量 s , 将 λ 改写成 y , 对偶问题等价地写成

$$\begin{aligned} \max_x \quad & -\frac{1}{2} \|y\|_2^2 - b^T y, \\ \text{s.t.} \quad & A^T y - s = 0, \\ & \|s\|_\infty \leq \mu. \end{aligned}$$

对于上述对偶问题, 增广拉格朗日函数为

$$\begin{aligned} L_\sigma(y, s, \lambda) &= \frac{1}{2} \|y\|_2^2 + b^T y + \lambda^T (A^T y - s) + \frac{1}{2} \sigma \|A^T y - s\|_2^2, \\ & \|s\|_\infty \leq \mu. \end{aligned}$$

则增广拉格朗日函数法的迭代格式为

$$(y^{k+1}, s^{k+1}) = \arg \min_{y,s} \{ L_{\sigma_k}(y, s; \lambda^k) \}, \quad (6.3a)$$

$$\lambda^{k+1} = \lambda^k + \sigma_k (A^T y^{k+1} - s^{k+1}), \quad (6.3b)$$

$$\sigma_{k+1} = \rho \sigma_k, \quad \sigma_k \uparrow \sigma_\infty \leq \infty. \quad (6.3c)$$

用最优性条件, 在 (6.3a) 式中消去 s , 得到极小化问题

$$\begin{aligned} \min_s \quad & \sigma \left\| A^T y - s + \frac{\lambda}{\sigma} \right\|_2^2 \\ \text{s.t.} \quad & \|s\|_\infty \leq \mu \end{aligned}$$

的解 $s = \mathcal{P}_{\|s\|_\infty \leq \mu} \left(A^T y + \frac{\lambda}{\sigma} \right)$. 将 s 的表达式代入 (6.3a) 即可消去 s , 只更新 y , 从而减小了计算的困难. \square

6.9 考虑线性规划问题

$$\min_{x \in \mathbb{R}^n} c^T x, \quad \text{s.t.} \quad Ax = b, x \geq 0.$$

写出该问题以及其对偶问题的增广拉格朗日函数法.

解 (丁思哲). 线性规划原问题的增广拉格朗日函数为

$$L_\sigma(x, \lambda) = c^T x + \lambda^T (Ax - b) + \frac{1}{2} \sigma \|Ax - b\|_2^2, \quad x \geq 0.$$

根据增广拉格朗日函数, 设计增广拉格朗日函数法迭代格式为

$$x^{k+1} = \arg \min_{x \geq 0} \{L_{\sigma_k}(x, \lambda^k)\}, \quad (6.4a)$$

$$\lambda^{k+1} = \lambda^k + \sigma_k (Ax^{k+1} - b), \quad (6.4b)$$

$$\sigma_{k+1} = \min \{\rho \sigma_k, \bar{\sigma}\}. \quad (6.4c)$$

线性规划的对偶问题为

$$\begin{aligned} \min_y \quad & b^T y, \\ \text{s.t.} \quad & A^T y + c \leq 0. \end{aligned}$$

引入松弛变量 s , 等价于

$$\begin{aligned} \min_y \quad & -b^T y, \\ \text{s.t.} \quad & A^T y + s - c = 0, \\ & s \geq 0. \end{aligned}$$

根据上述对偶问题, 增广拉格朗日函数为

$$L_\sigma(y, s, \lambda) = -b^T y + \lambda^T (A^T y + s - c) + \frac{1}{2} \sigma \|A^T y + s - c\|_2^2, \quad s \geq 0,$$

由此设计增广拉格朗日函数法迭代格式为

$$(y^{k+1}, s^{k+1}) = \arg \min_{y, s \geq 0} \{L_{\sigma_k}(y, s, \lambda^k)\}, \quad (6.5a)$$

$$\lambda^{k+1} = \lambda^k + \sigma_k (A^T y^{k+1} + s^{k+1} - c), \quad (6.5b)$$

$$\sigma_{k+1} = \min \{\rho \sigma_k, \bar{\sigma}\}. \quad (6.5c)$$

用最优性条件将 (6.5a) 中的 s 用 y 表示, 即对极小化问题

$$\begin{aligned} \min_s \quad & \sigma \left\| A^T y + s - c + \frac{\lambda}{\sigma} \right\|_2^2 \\ \text{s.t.} \quad & s \geq 0 \end{aligned}$$

解得 $s = \mathcal{P}_{\mathbb{R}_+^n}(c - A^T y - \lambda/\sigma)$. 将此式代入 (6.5a) 中即可. \square

第七章 复合优化算法

7.1 证明例 8.2 中的运算法则成立.

解 (丁思哲).

(1) 设 $u = \text{prox}_h(x)$, 则由最优性条件,

$$\begin{aligned} u = \text{prox}_h(x) &\Leftrightarrow x - u \in \partial h(u) \\ &\Leftrightarrow x - u \in \partial g(\lambda u + a). \quad (\lambda > 0) \end{aligned}$$

设 $\alpha = \lambda u + a$, 根据次梯度线性映射计算法则, 有

$$u = \text{prox}_h(x) \Leftrightarrow x - \frac{\alpha}{\lambda} + \frac{a}{\lambda} \in \lambda \partial g(\alpha) = \partial \lambda g(\alpha),$$

故

$$\begin{aligned} u = \text{prox}_h(x) &\Leftrightarrow \lambda x + a - \alpha \in \partial \lambda^2 g(\alpha) \\ &\Leftrightarrow \alpha = \text{prox}_{\lambda^2 g}(\lambda x + a). \end{aligned}$$

再代入 $\alpha = \lambda u + a$, 得到

$$u = \frac{1}{\lambda}(\text{prox}_{\lambda^2 g}(\lambda x + a) - a) = \text{prox}_h(x).$$

(2) 与 (1) 几乎一致的做法, 注意

$$x - u \in \partial h(u) \Leftrightarrow x - u \in \partial \lambda g\left(\frac{u}{\lambda}\right),$$

设 $\alpha = \frac{u}{\lambda}$, 则可导出

$$u = \lambda \text{prox}_{\lambda^{-1}g}(\lambda^{-1}x) = \text{prox}_h(x).$$

(3) 与 (1) 几乎一致的做法, 注意

$$x - u \in \partial h(u) \Leftrightarrow \partial g(u) + a,$$

则 $u = \text{prox}_g(x - a)$.

(4) 设 β 为邻近算子, 有

$$\begin{aligned}
 \beta = \text{prox}_h(x) &\Leftrightarrow x - \beta \in \partial h(\beta) \\
 &\Leftrightarrow x - \beta \in \partial g(\beta) + u(\beta - a) \\
 &\Leftrightarrow \frac{x + ua}{u + 1} - \beta \in \partial \frac{1}{u + 1} g(\beta) \\
 &\Leftrightarrow \beta = \text{prox}_{\theta g}(\theta x + (1 - \theta)a),
 \end{aligned}$$

其中 θ 如定理所定义.

(5) 取邻近算子 $\begin{bmatrix} u \\ v \end{bmatrix} = \text{prox}_h \left(\begin{bmatrix} x \\ y \end{bmatrix} \right)$, 则

$$\begin{aligned}
 &\begin{bmatrix} x \\ y \end{bmatrix} - \begin{bmatrix} u \\ v \end{bmatrix} \in \partial h \left(\begin{bmatrix} u \\ v \end{bmatrix} \right) \\
 \Leftrightarrow &\begin{bmatrix} x \\ y \end{bmatrix} - \begin{bmatrix} u \\ v \end{bmatrix} \in \partial \varphi_1(u) + \partial \varphi_2(v),
 \end{aligned}$$

由此可得 $u = \text{prox}_{\varphi_1}(x), v = \text{prox}_{\varphi_2}(y)$, 那么

$$\text{prox}_h \left(\begin{bmatrix} x \\ y \end{bmatrix} \right) = \begin{bmatrix} u \\ v \end{bmatrix} = \begin{bmatrix} \text{prox}_{\varphi_1}(x) \\ \text{prox}_{\varphi_2}(y) \end{bmatrix}. \quad \square$$

7.2 求下列函数的邻近算子:

(a) $f(x) = I_C(x)$, 其中 $C = \{(x, t) \in \mathbb{R}^{n+1} \mid \|x\|_2 \leq t\}$;

(b) $f(x) = \inf_{y \in C} \|x - y\|$, 其中 C 是闭凸集;

(c) $f(x) = \frac{1}{2}(\inf_{y \in C} \|x - y\|)^2$, 其中 C 是闭凸集.

解 (丁思哲).

(a) 由定义, 临近算子

$$\begin{aligned}
 u &= \arg \min_u \left\{ I_C(u) + \frac{1}{2} \|u - x\|^2 \right\} \\
 &= \arg \min_{\|u\|_2 \leq t} \{ \|u - x\|^2 \} \\
 &= \mathcal{P}_{\|x\|_2 \leq t}(x).
 \end{aligned}$$

(b) $f(x) = \inf_{y \in C} \|x - y\|$. 我们先求 f 在 \hat{x} 处的次梯度.

若 $f(\hat{x}) = 0$, 则 $g = 0$; 若 $f(\hat{x}) > 0$, 取 \hat{y} 为 \hat{x} 在 C 上的投影, 即 $\hat{y} = \mathcal{P}_C(\hat{x})$, 则次梯度为

$$g \in \partial \|\hat{x} - \mathcal{P}_C(\hat{x})\| \subseteq \partial f(\hat{x}).$$

特别, 若 $\|\cdot\| \triangleq \|\cdot\|_2$, 则 $\hat{x} \neq \mathcal{P}_C(\hat{x})$ 时,

$$g = \frac{\hat{x} - \mathcal{P}_C(\hat{x})}{\|\hat{x} - \mathcal{P}_C(\hat{x})\|_2} \in \partial f(\hat{x}),$$

故设 $u = \text{prox}_f(x)$, 则 $x - u \in \partial f(u)$, 结合上式可知

$$x - u \in \begin{cases} \partial \|u - \mathcal{P}_C(u)\|, & f(u) > 0, \\ \{0\}, & f(u) = 0. \end{cases}$$

因此当 $x = y$ 时, $u = x$; 当 $x \neq y$ 时, u 满足 $x - u \in \partial \|u - \mathcal{P}_C(u)\|$.

特别, 若 $\|\cdot\| \triangleq \|\cdot\|_2$, 则 $x \neq y$ 时, $x - u = \frac{u - \mathcal{P}_C(u)}{\|u - \mathcal{P}_C(u)\|}$, 进而从中解出 u 即可.

(c) $f(x) = \frac{1}{2} \inf_{y \in C} \|x - y\|^2$, 求 f 在 \hat{x} 处的次梯度.

若 $f(\hat{x}) = 0$, 则 $g = 0$; 否则, 取 $\hat{y} = \mathcal{P}_C(\hat{x})$, 则

$$g \in \partial \left(\frac{1}{2} \|\hat{x} - \mathcal{P}_C(\hat{x})\|^2 \right).$$

特别地, 若 $\|\cdot\| \triangleq \|\cdot\|_2$, 则 $y = \hat{x} - \mathcal{P}_C(\hat{x})$. 设 $u = \text{prox}_f(x)$, 则由极小化原理可知

$$x - u \in \partial \left(\frac{1}{2} \|u - \mathcal{P}_C(u)\|^2 \right).$$

特别地, 若 $\|\cdot\| \triangleq \|\cdot\|_2$, 则 u 进一步满足 $2u - \mathcal{P}_C(u) = x$. \square

7.3 对一般复合优化问题的加速算法 (算法 8.9), 试证明:

- (a) 当 $t_k = \gamma_k \lambda_k$ 且 $h(x) = 0$ 时, 算法 8.9 等价于第二类 Nesterov 加速算法;
- (b) 当 $t_k = \lambda_k$ 时, 算法 8.9 等价于近似点梯度法.

解 (丁思哲).

(a) 在算法 8.9 中, 更新 z^k, y^k, x^k 的方式为

$$z^k = \gamma_k y^{k-1} + (1 - \gamma_k) x^{k-1}, \quad (7.1)$$

$$y^k = \text{prox}_{\lambda_k h}(y^{k-1} - \lambda_k \nabla f(z^k)), \quad (7.2)$$

$$x^k = \text{prox}_{t_k h}(z^k - t_k \nabla f(z^k)). \quad (7.3)$$

取 $t_k = \gamma_k \lambda_k$, 则 (7.2) 式化为

$$y^k = \text{prox}_{\frac{t_k}{\gamma_k} h}(y^{k-1} - \frac{t_k}{\gamma_k} \nabla f(z^k)).$$

最后证明 $x^k = (1 - \gamma_k) x^{k-1} + \gamma_k y^k$ 即可. 注意 (7.1) 式有

$$(1 - \gamma_k) x^{k-1} = z^k - \gamma_k y^{k-1},$$

故即证

$$x^k = z^k + \gamma_k (y^k - y^{k-1}). \quad (7.4)$$

由定义,

$$x^k = \arg \min_u \left\{ t_k h(u) + \frac{1}{2} \|u - z^k + t_k \nabla f(z^k)\|^2 \right\},$$

取 $\alpha = (u - z^k)/\gamma_k + y^{k-1}$, 代入上式, 即产生问题

$$\min_{\alpha} \left\{ \lambda_k h(\alpha) + \frac{1}{2} \|\alpha - y^{k-1} + \lambda_k \nabla f(z^k)\|^2 \right\},$$

这恰好对应 (7.2) 式, 我们知道极小点为 $\alpha = y^k$. 因此, 对 $\alpha = (u - z^k)/\gamma_k + y^{k-1}$, 分别优化上述 2 个问题, 代入 $\alpha = y^k$, $u = x^k$, 得到 (7.4) 式, 证毕.

(b) $\lambda_k = t_k$ 时, 算法 8.9 为

$$z^k = \gamma_k y^{k-1} + (1 - \gamma_k) x^{k-1}, \quad (7.5)$$

$$y^k = \text{prox}_{t_k h}(y^{k-1} - t_k \nabla f(z^k)), \quad (7.6)$$

$$x^k = \text{prox}_{t_k h}(z^k - t_k \nabla f(z^k)). \quad (7.7)$$

若证明其与近似点梯度法等价, 只需要证明 $y^k = x^k$.

由 (7.7) 得

$$x^k = \arg \min_u \left\{ t_k h(u) + \frac{1}{2} \|u - z^k + t_k \nabla f(z^k)\|^2 \right\},$$

令 $\alpha = u + (1 - \gamma_k)x^{k-1} - (1 - \gamma_k)y^{k-1}$, 代入上式, 即产生问题

$$\min_{\alpha} \{t_k h(\alpha) + \frac{1}{2} \|\alpha - y^{k-1} + t_k \nabla f(z^k)\|^2\},$$

这恰好对应 (7.6) 式, 我们知道极小点为 $\alpha = y^k$. 因此, 对 $\alpha = (u - z^k)/\gamma_k + y^{k-1}$, 分别优化上述 2 个问题, 代入 $\alpha = y^k$, $u = x^k$, 得到 $x^k = y^k$, 证毕. \square

7.4 假设 f 是闭凸函数, 证明 Moreau 分解的推广成立, 即对任意的 $\lambda > 0$ 有

$$x = \text{prox}_{\lambda f}(x) + \lambda \text{prox}_{\lambda^{-1}f^*}\left(\frac{x}{\lambda}\right) \quad \forall x.$$

提示: 利用 Moreau 分解的结论.

解 (邓展望). 由 Moreau 分解的结论可知

$$\text{prox}_{\lambda f}(x) = x - \text{prox}_{(\lambda f)^*}(x) = x - \text{prox}_{\lambda f^*}(\cdot/\lambda)(x),$$

再根据 prox 算子的性质可知若 $f(x) = \lambda g(x/\lambda)$, 则有

$$\text{prox}_f(x) = \lambda \text{prox}_{g/\lambda}(x/\lambda).$$

再代入 f^* 得

$$x = \text{prox}_{\lambda f}(x) + \lambda \text{prox}_{\lambda^{-1}f^*}\left(\frac{x}{\lambda}\right), \quad \forall x. \quad \square$$

7.5 写出关于 LASSO 问题的鞍点问题形式, 并写出原始 - 对偶混合梯度算法和 Chambolle-Pock 算法.

解 (丁思哲). LASSO 问题的形式为

$$\min_x \frac{1}{2} \|Ax - b\|_2^2 + \mu \|x\|_1,$$

记 $f(x) = \mu \|x\|_1$, $h(x) = \|x - b\|_2^2/2$, 则 $f(x)$ 与 $h(x)$ 都是适当的闭凸函数, 且 $h(x)$ 具有自共轭性.

鞍点形式 (a) 及其算法

设 $h(x)$ 的共轭函数为 $h^*(z)$, 则鞍点问题的形式为

$$\min_x \max_z \{f(x) - h^*(z) + z^T Ax\}.$$

其中 $h^*(z) = \sup_{y \in \text{dom } h} \{z^T y - \|y - b\|_2^2 / 2\}$.

由最优性条件, 对 $h^*(z)$ 取 $y = z + b$, 得 $h^*(z) = \|z\|_2^2 / 2 + z^T b$, 故鞍点问题的形式具体为

$$\min_x \max_z \left\{ \mu \|x\|_1 + z^T A x - \frac{1}{2} \|z\|_2^2 - b^T z \right\}. \quad (7.8)$$

对于鞍点问题, 可设计 PDHG 算法. 具体而言, 在第 $k+1$ 步的更新中, 先固定 x^k , 对 z^k 做梯度上升; 再固定 z^k , 对 x^k 做梯度下降. 因此, 迭代格式为

$$\begin{aligned} z^{k+1} &= \arg \max_z \left\{ -h^*(z) + (z - z^k)^T A x^k - \frac{1}{2\delta_k} \|z - z^k\|_2^2 \right\} \\ &= \text{prox}_{\delta_k h^*}(z^k + \delta_k A x^k) \\ &= \frac{\delta_k (A x^k - b) + z^k}{\delta_k + 1}. \\ x^{k+1} &= \arg \min_x \left\{ f(x) + (x - x^k)^T A^T z^{k+1} + \frac{1}{2\alpha_k} \|x - x^k\|_2^2 \right\} \\ &= \text{prox}_{\alpha_k f}(x^k - \alpha_k A^T z^{k+1}) \\ &= \text{prox}_{\alpha_k \mu \|\cdot\|_1}(x^k - \alpha_k A^T z^{k+1}). \end{aligned}$$

上述迭代格式对应的 Chambolle-Pock 算法为

$$\begin{aligned} z^{k+1} &= \frac{\delta_k (A y^k - b) + z^k}{\delta_k + 1}, \\ x^{k+1} &= \text{prox}_{\alpha_k \mu \|\cdot\|_1}(x^k - \alpha_k A^T z^{k+1}), \\ y^{k+1} &= 2x^{k+1} - x^k. \end{aligned}$$

鞍点形式 (b) 及其算法

再以格式 (8.5.11) 写鞍点形式. LASSO 问题等价于

$$\begin{aligned} \min_{x, z} \quad & \mu \|x\|_1 + \frac{1}{2} \|z - b\|_2^2, \\ \text{s.t.} \quad & A x - z = 0, \end{aligned}$$

并不妨设 $f(x) = \mu \|x\|_1$, 且 $h(z) = \|z - b\|_2^2 / 2$.

直接用带约束问题的拉格朗日函数定义鞍点问题, 即

$$\begin{aligned} \min_{x, z} \max_{\lambda} \quad & L(x, z; \lambda) \\ = \min_{x, z} \max_{\lambda} \quad & \left\{ \mu \|x\|_1 + \frac{1}{2} \|z - b\|_2^2 + \lambda^T (A x - z) \right\}. \end{aligned}$$

这种鞍点问题也对应一类 PDHG 算法. 具体而言, 在第 $k+1$ 步迭代, 先固定 (x^k, z^k) , 更新 λ^k ; 再固定 λ^{k+1} , 联合更新 (x^k, z^k) . 其格式为

$$\begin{aligned}\lambda^{k+1} &= \arg \max_{\lambda} \left\{ (Ax^k - z^k)^T (\lambda - \lambda^k) - \frac{1}{2\delta_k} \|\lambda - \lambda^k\|_2^2 \right\} \\ &= \lambda^k + \delta_k (Ax^k - z^k), \\ (x^{k+1}, z^{k+1}) &= \arg \min_{x, z} \left\{ f(x) + h(z) + (\lambda^{k+1})^T (A(x - x^k) - (z - z^k)) \right. \\ &\quad \left. + \frac{1}{2\alpha_k} \|x - x^k\|_2^2 + \frac{1}{2\beta_k} \|z - z^k\|_2^2 \right\} \\ &= (\text{prox}_{\alpha_k f}(x^k - \alpha_k A^T \lambda^{k+1}), \text{prox}_{\beta_k h}(z^k + \beta_k \lambda^{k+1})) \\ &= \left(\text{prox}_{\alpha_k f}(x^k - \alpha_k A^T \lambda^{k+1}), \frac{z^k + \beta_k (b + \lambda^{k+1})}{\beta_k + 1} \right).\end{aligned}$$

上述迭代格式对应的 Chambolle-Pock 算法为

$$\begin{aligned}\lambda^{k+1} &= \lambda^k + \delta_k (Ap^k - q^k), \\ x^{k+1} &= \text{prox}_{\alpha_k f}(x^k - \alpha_k A^T \lambda^{k+1}), \\ z^{k+1} &= \frac{z^k + \beta_k (b + \lambda^{k+1})}{\beta_k + 1}, \\ p^{k+1} &= 2x^{k+1} - x^k, \\ q^{k+1} &= 2z^{k+1} - z^k.\end{aligned}$$

最后课本中还列举了一类鞍点格式 (8.5.12), 如上做法, 故不再赘述. \square

7.6 设函数 $f(x_1, x_2) = |x_1 - x_2| - \min\{x_1, x_2\}$, 其定义域为 $[0, 1] \times [0, 1]$. 试推导基于格式 (8.4.3) 的分块坐标下降法 (x_1 和 x_2 分别看做一个变量块), 此算法是否收敛?

解 (丁思哲). 由于 $\min\{x_1, x_2\} = (x_1 + x_2 - |x_1 - x_2|)/2$, 故函数可进一步写成

$$f(x_1, x_2) = \frac{3}{2} |x_1 - x_2| - \frac{1}{2} (x_1 + x_2).$$

将 x_1, x_2 视为 2 个变量块, 进行分块下降.

当固定 x_1 时, 解得

$$x_1 = \arg \min_{x_2} f(x_1, x_2),$$

同理可得当固定 x_2 时, 解得

$$x_2 = \arg \min_{x_1} f(x_1, x_2),$$

因此基于格式 (8.4.3) 的分块下降法为

$$\begin{cases} x_2^{k+1} = x_1^k, \\ x_1^{k+1} = x_2^{k+1}. \end{cases}$$

由上述格式立即可得算法收敛, 因为 $x_1^{k+1} = x_1^k$, 而

$$x_2^{k+2} = x_1^{k+1} = x_1^k = x_2^{k+1}.$$

但明显该算法在本例不具有全局优化的能力. \square

7.7 试对分组 LASSO 问题 (即例 8.7) 推导出基于格式 (8.4.4) 的分块坐标下降法.

解 (邓展望). 首先写出该问题的形式:

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} \|Ax - b\|_2^2 + \mu_1 \sum_{\ell=1}^G \sqrt{n_\ell} \|x_{\mathcal{I}_\ell}\|_2, \quad (7.9)$$

所以可知第 i 块变量即为 x 的第 i 组分量. 为了方便起见, 记 $A = (A_1, \dots, A_G)$, $x^T = (x_1, \dots, x_G)$ 则每次迭代目标函数可简化为

$$\begin{aligned} & \arg \min_{x_i} \left\{ \frac{1}{2} \|Ax - b\|_2^2 + \mu_1 \sum_{\ell=1}^G \sqrt{n_\ell} \|x_{\mathcal{I}_\ell}\|_2 \right\} \\ &= \arg \min_{x_i} \left\{ \frac{1}{2} \|A_i x_i\|_2^2 + \left(\sum_{k \neq i} x_k^T A_k^T - b^T \right) A_i x_i + \mu_i \sqrt{n_i} \|x_i\|_2 \right\} \\ &= \arg \min_{x_i} \left\{ \frac{1}{2} x_i^T M_i x_i + p_i^T x_i + \lambda \|x_i\| \right\}, \end{aligned}$$

其中 $M_k = A_k^T A_k$, $p_k^T = \left(\sum_{k \neq i} x_k^T A_k^T - b^T \right) A_i$, $\lambda = \mu_i \sqrt{n_i}$. 由最优性条件可得当 $x_i \neq 0$ 时方程

$$M_i x_i + p_i = \frac{x_i}{\|x_i\|}$$

成立. 若 $\|p_i\| \leq \lambda$, 则有 $p_i^T x_i + \lambda \|x_i\| \geq 0$, 此时 $x_i = 0$. 而若 $x_i = 0$, 则有 $p_i + \lambda g_0 = 0$, 其中 g_0 为 $\|x\|$ 在 $x = 0$ 处的次梯度; 又由于 $\|g_0\| \leq 1$, 故有 $\|p_i\| \leq \lambda$. 所以 $x_i = 0$ 为最优解的充分必要条件为 $\|p_i\| \leq \lambda$. 综上, 若 $\|p_i\| \leq \lambda$ 则 $x_i = 0$, 否则 $x_i = (M_i + \frac{\lambda}{\|x_i\|})^{-1} p_i$. \square

注: 方程

$$M_i x_i + p_i = \frac{x_i}{\|x_i\|}$$

的求解可用信赖域方法, 具体可见:

Q,Z.,Scheinberg, K. & Goldfarb,D. Efficient block-coordinate descent algorithms for the Group Lasso.Math.Prog. Comp.5,143-169(2013).

7.8 考虑约束优化问题

$$\begin{aligned} \min \quad & \max\{e^{-x} + y, y^2\}, \\ \text{s.t.} \quad & y \geq 2, \end{aligned}$$

其中 $x, y \in \mathbb{R}$ 为自变量.

(a) 通过引入松弛变量 z , 试说明该问题等价于

$$\begin{aligned} \min \quad & \max\{e^{-x} + y, y^2\} + I_{\mathbb{R}_+}(z), \\ \text{s.t.} \quad & y - z = 2; \end{aligned}$$

(b) 推导 (a) 中问题的对偶问题, 并求出原始问题的最优解;

(c) 对 (a) 中的问题形式, 使用 ADMM 求解时可能会遇到什么问题?

解 (邓展望).

(a) 引入松弛变量 z , 将原问题变为:

$$\begin{aligned} \min \quad & \max\{e^{-x} + y, y^2\}, \\ \text{s.t.} \quad & y - z = 2, z \geq 0. \end{aligned}$$

则可知原问题等价于

$$\begin{aligned} \min \quad & \max\{e^{-x} + y, y^2\} + I_{\mathbb{R}_+}(z), \\ \text{s.t.} \quad & y - z = 2. \end{aligned}$$

(b) 写出 (a) 的拉格朗日函数:

$$L(x, y, \lambda, z) = \max\{e^{-x} + y, y^2\} + I_{\mathbb{R}_+}(z) + \lambda(y - z - 2).$$

又若求 $\inf_{x, y, z} L(x, y, \lambda, z)$, 此时应有 $\lambda \leq 0, x = +\infty, z = 0$.

所以成立

$$\inf_{x, y, z} L(x, y, \lambda, z) = \begin{cases} -2\lambda, & \lambda \geq -1, \\ 1 - \lambda, & \lambda \in [-2, -1] \\ -2\lambda - \frac{\lambda^2}{4}, & \lambda < -2. \end{cases}$$

求解该问题得 $z = 0, x = \infty, y = 2, \lambda = -4$.

(c) 由于在迭代过程中每一步为

$$(x^{k+1}, y_{k+1}) = \arg \min_{(x, y)} \{ \max\{e^{-x} + y, y^2\} + I_{\mathbb{R}_+}(z) + \lambda(y - z - 2) + \frac{\rho}{2}(y - z - 2)^2 \},$$

若初始条件为 $z = 0, \lambda = 0$, 此时无法在 \mathbb{R}^2 中找到最小值点 (x, y) , 因此 ADMM 的子迭代不是良定义的. 必须对原问题进行某种变形. \square

7.9 写出对于线性规划对偶问题运用 ADMM 的迭代格式, 以及与之等价的对于原始问题的 DRS 格式, 并指出 ADMM 和 DRS 算法更新变量之间的关系.

解 (陈钺). 首先考虑线性规划的对偶问题

$$\begin{aligned} \max \quad & b^T y, \\ \text{s.t.} \quad & A^T y + s = c, \\ & s \geq 0. \end{aligned}$$

通过引入乘子 λ , 构造增广拉格朗日函数

$$L_\rho(s, y, \lambda) = -b^T y - \langle \lambda, A^T y + s - c \rangle + \frac{\rho}{2} \|A^T y + s - c\|^2.$$

对于 y 子问题,

$$\begin{aligned} y^{k+1} &= \arg \min_y L_\rho(s^k, y, \lambda^k) \\ &= \arg \min_y \left\{ -(A\lambda^k + b)^\top y + \frac{\rho}{2} \|A^\top y + s^k - c\|^2 \right\} \\ &= \frac{1}{\rho} (AA^\top)^{-1} (A\lambda^k + b + \rho A(c - s^k)). \end{aligned}$$

对于 s 子问题,

$$\begin{aligned} s^{k+1} &= \arg \min_{s \geq 0} L_\rho(s, y^{k+1}, \lambda^k) \\ &= \arg \min_{s \geq 0} \left\{ -\langle \lambda^k, s \rangle + \frac{\rho}{2} \|A^\top y^{k+1} + s - c\|^2 \right\} \\ &= \max\{c - A^\top y^{k+1} + \frac{1}{\rho} \lambda^k, 0\}. \end{aligned}$$

对于乘子 x , 我们使用常规更新, 由此得到 ADMM 的迭代格式

$$\begin{aligned} y^{k+1} &= \frac{1}{\rho} (AA^\top)^{-1} (A\lambda^k + b + \rho A(c - s^k)), \\ s^{k+1} &= \max\{c - A^\top y^{k+1} + \frac{1}{\rho} \lambda^k, 0\}, \\ \lambda^{k+1} &= \lambda^k - \tau \rho (A^\top y^{k+1} + s^{k+1} - c). \end{aligned}$$

现在我们引入示性函数, 将上述问题改写为可分的凸问题的形式:

$$\begin{aligned} \min \quad & -b^\top y + I_{\{s|s \geq 0\}}(s), \\ \text{s.t.} \quad & A^\top y + s = c. \end{aligned}$$

令 $f_1(y) = -b^\top y$, $f_2(s) = I_C(s)$, 其对偶问题为无约束的复合优化问题

$$\min_x \quad c^\top x + f_1^*(-Ax) + f_2^*(-x).$$

由共轭函数的定义,

$$f_1^*(z) = I_{\{z|z=-b\}}(z), \quad f_2^*(z) = I_{\{z|z \leq 0\}}(z).$$

由此得到无约束符合复合优化问题

$$\min_x \quad c^\top x + I_{\{x|Ax=b\}}(x) + I_{\{x|x \geq 0\}}(x).$$

注意到这个问题等价于线性规划的原问题. 令 $f(x) = c^T x + I_{\{x|Ax=b\}}(x)$, $h(x) = I_{\{x|x \geq 0\}}(x)$, 使用 DRS 算法, 得到迭代格式

$$\begin{aligned} u^{k+1} &= \text{prox}_{tf}(x^k - w^k) \\ &= \mathcal{P}_{\{x|Ax=b\}}(x^k - w^k - tc) \\ &= x^k - w^k - tc - A^T(AA^T)^{-1}(A(x^k - w^k - tc) - b), \\ x^{k+1} &= \text{prox}_{th}(w^k + u^{k+1}) \\ &= \max\{w^k + u^{k+1}, 0\}, \\ w^{k+1} &= w^k + u^{k+1} - x^{k+1}. \end{aligned}$$

现在我们讨论 ADMM 和 DRS 算法更新变量之间的关系. 根据定理 8.15 可知, 在由 DRS 算法产生的更新中, 分别存在

$$\begin{aligned} x_1^k &\in \partial f_1^*(-Au^{k+1}), \\ x_2^k &\in \partial f_2^*(-x^{k+1}), \end{aligned}$$

再令 $w^{k+1} = -tx_2^k$, $\lambda^k = -x^{k+1}$, 则导出

$$\begin{aligned} x_1^{k+1} &= \arg \min_{x_1} \left\{ -b^T x_1 - (\lambda^k)^T A^T x_1 + \frac{t}{2} \|A^T x_1 + x_2^k - c\|^2 \right\}, \\ x_2^{k+1} &= \arg \min_{x_2} \left\{ I_C(x_2) - (\lambda^k)^T x_2 + \frac{t}{2} \|A^T x_1^{k+1} + x_2 - c\|^2 \right\}, \\ \lambda^{k+1} &= \lambda^k - t(A^T x_1^{k+1} + x_2^{k+1} - c), \end{aligned}$$

对比可发现 ADMM 算法中的 y 对应 DRS 算法推出的 x_1 , s 对应 x_2 , 且 DRS 是 ADMM 算法的一类特殊形式, 其中 $\rho = t$ 且 $\tau = 1$. \square

7.10 考虑 ℓ_0 范数优化问题的罚函数形式:

$$\min \quad \lambda \|x\|_0 + \frac{1}{2} \|Ax - b\|^2,$$

其中 $A \in \mathbb{R}^{m \times n}$, $m < n$ 为实矩阵, $\|\cdot\|_0$ 为 ℓ_0 范数, 即非零元素的个数. 试针对 ℓ_0 范数优化问题形式化推导具有两个变量块的 ADMM 格式. 在算法中每个子问题是如何求解的?

解 (陈钺). 考虑上述问题的等价形式:

$$\begin{aligned} \min \quad & \lambda \|z\|_0 + \frac{1}{2} \|Ax - b\|^2, \\ \text{s.t.} \quad & x = z. \end{aligned}$$

写出该问题的增广拉格朗日函数. 引入乘子 λ 作用在约束 $x = z$ 上,

$$L_\rho(x, z, \lambda) = \|z\|_0 + \frac{1}{2}\|Ax - b\|^2 + \lambda^T(x - z) + \frac{\rho}{2}\|x - z\|^2.$$

在第 $(k+1)$ 步, 交替方向乘子法分别求解关于 x 和 z 的子问题更新 x^{k+1} 和 z^{k+1} .

对于 x 子问题,

$$\begin{aligned} x^{k+1} &= \arg \min_x L_\rho(x, z^k, \lambda^k) \\ &= \arg \min_x \left\{ \frac{1}{2}\|Ax - b\|^2 + \frac{\rho}{2} \left\| x - z^k + \frac{1}{\rho}\lambda^k \right\|^2 \right\} \\ &= (A^T A + \rho I)^{-1} (A^T b + \rho z^k - \lambda^k). \end{aligned}$$

对于 z 子问题,

$$\begin{aligned} z^{k+1} &= \arg \min_z L_\rho(x^{k+1}, z, \lambda^k) \\ &= \arg \min_z \left\{ \|z\|_0 + \frac{\rho}{2} \left\| x^{k+1} - z + \frac{1}{\rho}\lambda^k \right\|^2 \right\}. \end{aligned}$$

注意到对于 z^{k+1} 的某一分量, 若其不为零, 则取值与 $x^{k+1} + \frac{1}{\rho}\lambda^k$ 的对应分量相等是目标函数最小. 令 $c = x^{k+1} + \frac{1}{\rho}\lambda^k$, 则 z^{k+1} 满足

$$z_i^{k+1} = \begin{cases} c_i, & \frac{\rho}{2}c_i^2 \geq 1, \\ 0, & \frac{\rho}{2}c_i^2 < 1. \end{cases}$$

对于乘子 λ , 有常规更新

$$\lambda^{k+1} = \lambda^k + \tau\rho(x^{k+1} - z^{k+1}).$$

因此两个子问题都存在显式解. □

7.11 试说明 LASSO 对偶问题中, 若在问题 (8.6.27) 中对约束

$$A^T y + z = 0$$

引入乘子 x , 则 x 恰好对应 LASSO 原始问题 (8.6.26) 中的自变量.

解 (邓展望). 写出该问题的拉格朗日函数:

$$b^T y + \frac{1}{2} \|y\|^2 + I_{\|z\|_\infty \leq \mu}(z) - x^T (A^T y + z). \quad (7.10)$$

再由

$$\begin{aligned} & \inf_{y,z} b^T y + \frac{1}{2} \|y\|^2 + I_{\|z\|_\infty \leq \mu}(z) - x^T (A^T y + z) \\ &= \inf_{y,z} \frac{1}{2} \|y - Ax - b\|^2 - \frac{1}{2} \|Ax - b\|^2 + I_{\|z\|_\infty \leq \mu}(z) - x^T z \quad (7.11) \\ &= -\frac{1}{2} \|Ax - b\|^2 - \mu \|x\|_1, \end{aligned}$$

所以该问题的对偶问题为

$$\max \quad -\mu \|x\|_1 - \frac{1}{2} \|Ax - b\|^2, \quad (7.12)$$

它与 LASSO 问题等价. 所以, 拉格朗日乘子 x 对应原问题自变量 x . \square

7.12 实现关于 LASSO 问题使用以下算法的程序, 并比较它们的效率

- (a) 近似点梯度算法;
- (b) Nesterov 加速算法;
- (c) 交替方向乘子法;
- (d) Chambolle-Pock 算法;
- (e) 分块坐标下降法;
- (f) 随机近似点梯度算法.

解. 见教材[代码主页](#), 此处从略. \square

7.13 设 $f(x) = \frac{1}{N} \sum_{i=1}^N f_i(x)$, 其中每个 $f_i(x)$ 是可微函数, 且 $f(x)$ 为梯度 L -利普希茨连续的. $\{x^k\}$ 是由随机梯度下降法产生的迭代序列, s_k 为第 k 步随机抽取的下标. 证明:

$$\mathbb{E}[\|\nabla f_{s_k}(x^k)\|^2] \leq \mathbb{E}[\|x^k - x^*\|^2] + \alpha_k \mathbb{E}[\|\nabla f_{s_k}(x^k) - \nabla f(x^k)\|^2],$$

其中 x^* 是 $f(x)$ 的一个最小值点, α_k 为第 k 步的步长.

订正 原问题有误, 应改为证明:

$$\mathbb{E}[\|\nabla f_{s_k}(x^k)\|^2] \leq L^2 \mathbb{E}[\|x^k - x^*\|^2] + \mathbb{E}[\|\nabla f_{s_k}(x^k) - \nabla f(x^k)\|^2].$$

解 (邓展望).

$$\begin{aligned}
\mathbb{E}[\|\nabla f_{s_k}(x^k)\|^2] &= \mathbb{E}[\|\nabla f_{s_k}(x^k) - \nabla f(x^k) + \nabla f(x^k)\|^2] \\
&= \mathbb{E}[\|\nabla f_{s_k}(x^k) - \nabla f(x^k)\|^2] + \mathbb{E}[(\nabla f_{s_k}(x^k) - \nabla f(x^k))^T (\nabla f(x^k))] \\
&\quad + \mathbb{E}[\|\nabla f(x^k)\|^2] \\
&= \mathbb{E}[\|\nabla f_{s_k}(x^k) - \nabla f(x^k)\|^2] + \mathbb{E}[(\nabla f_{s_k}(x^k) - \nabla f(x^k))^T (\nabla f(x^k))] \\
&\quad + \mathbb{E}[\|\nabla f(x^k) - \nabla f(x^*)\|^2] \\
&\leq L^2 \mathbb{E}[\|x^k - x^*\|^2] + \mathbb{E}[\|\nabla f_{s_k}(x^k) - \nabla f(x^k)\|^2].
\end{aligned}$$

□

7.14 在 SAGA 算法中, 每一步的下降方向取为:

$$v^k = \nabla f_{s_k}(x^k) - g_{s_k}^{k-1} + \frac{1}{N} \sum_{i=1}^N g_i^{k-1},$$

假设初值 $g_i^0 = 0, i = 1, 2, \dots, N$, 证明:

$$\mathbb{E}[v^k | s_1, s_2, \dots, s_{k-1}] = \nabla f(x^k).$$

解 (邓展望).

$$\begin{aligned}
&\mathbb{E}[v^k | s_1, s_2, \dots, s_{k-1}], \\
&= \mathbb{E}[\nabla f_{s_k}(x^k) - g_{s_k}^{k-1} + \frac{1}{N} \sum_{i=1}^N g_i^{k-1} | s_1, s_2, \dots, s_{k-1}] \\
&= \mathbb{E}[\nabla f_{s_k}(x^k)] + \mathbb{E}[-g_{s_k}^{k-1} + \frac{1}{N} \sum_{i=1}^N g_i^{k-1} | s_1, s_2, \dots, s_{k-1}] \quad \square \\
&= \nabla f(x^k) - \frac{1}{N} \sum_{i=1}^N g_i^{k-1} + \frac{1}{N} \sum_{i=1}^N g_i^{k-1} \\
&= \nabla f(x^k).
\end{aligned}$$

更新历史

2021.12.21-2022.05.09

- 版本 v1.0 更新. 本次更新主要提供教材全部习题的参考解答 (包括资料), 是正式发布的第一版.
- **(最新)** 版本 v1.01 更新. 本次更新修改了部分题目的答案.

致谢

本书内容在北京大学数学科学学院多次开设的“凸优化”和“大数据分析中的算法”课程中使用，感谢选课同学的反馈和支持.