

应用运筹学基础：组合优化 (5) - 近似算法选讲 (3)

这节课首先介绍了 bin packing 的另一种线性规划模型：configuration LP，之后提出了一种渐进比为 1 的 bin packing 近似算法。

Configuration LP

我们将 n 个物品按体积分类，设共有 k 种不同的体积，记为 c_1, c_2, \dots, c_k ，每种体积有物品 b_1, b_2, \dots, b_k 个。

对于一个 bin，我们枚举体积为 c_1 的物品放几个， c_2 的放几个， \dots ， c_k 的放几个。

假设一共有 N 种不同的方案（又称为 pattern），记 $t_{i,j}$ 表示第 i 种方案中，体积为 c_j 的物品放了几个。我们设 x_i 表示对一个 bin packing 问题得到的答案中，第 i 种方案的 bin 用了几个。

$$\min_x \sum_{i=1}^N x_i$$

那么，我们能写出 bin packing 的线性规划问题：

$$\begin{aligned} \text{s.t.} \quad & \sum_{i=1}^N t_{i,j} x_i \geq b_j \quad \forall j \in \{1, 2, \dots, k\} \\ & x \geq 0 \end{aligned}$$

这个线性规划看起来变量很多，但是可以通过某种神奇的方法在比较好的多项式时间内求解。

近似算法

下面将提出一种渐进比为 1 的近似算法。记 $N(I)$ 表示该算法对 bin packing 的实例 I 算出来的答案，我们将要证明 $N(I) \leq \text{OPT}_{LP}(I) + O(\log^2 \text{OPT}_{LP}(I))$ 。算法步骤如下：

1. 记 $c(I)$ 表示实例 I 中物品的体积总和，先将体积小于 $\frac{1}{c(I)}$ 的物品拿走。等其它物品用迭代算法分配完后，再把小的物品用 first fit 安排进去。

\2. 使用迭代算法分配剩下的物品。

为什么最后分配“小”的物品不影响结论呢？下面先证明一个引理。

引理： 设 I 为 bin packing 问题的实例， g 是一个 $0 \sim 1$ 之间的实数。我们称体积至少为 $\frac{g}{2}$ 的物品为“大”物品，其它物品是“小”物品。我们首先分配大物品，设一共用了 A 个 bin。此时再用 first fit 把小物品也分配进去，则总共使用的 bin 数至多为 $\max(A, (1 + g)c(I) + 1)$ 。

证明： 设总共使用的 bin 数量为 B 。如果最后的 first fit 没有再开新的 bin，那么 $B = A$ ；否则至多有一个 bin 体积小于 $1 - \frac{g}{2}$ ，那么我们可以推出 $c(I) \geq (1 - \frac{g}{2})(B - 1)$ ，再结合 $0 \leq g \leq 1$ ，就有 $B \leq \frac{2}{2-g}c(I) + 1 \leq (1 + g)c(I) + 1$ 。

回到我们的算法，算法的第 1 步其实就是让 $\frac{1}{c(I)} = \frac{g}{2}$ ，即 $c(I) = \frac{2}{g}$ 。只要有 $c(I) \geq 2$ （ $c(I) < 2$ 用 first fit 就行了，反正要证的是渐进比嘛...），那么用 first fit 分配小物品后，使用的总 bin 数就是 $(1 + \frac{2}{c(I)})c(I) + 1 = c(I) + 3$ （然后和 A 取个 max），不改变我们渐进比为 1 的结论。下面我们只要证明 A 也符合结论就行了。

迭代算法与证明

下面说明要用到的迭代算法，并证明算法的结果仍然符合渐进比为 1 的结论。每一次迭代考虑当前的实例 I ，进行以下步骤：

第一步

求出 configuration LP 的解。设第 i 个 pattern 用了 x_i 次，由于 LP 只有 k 个限制，那么非零量至多只有 k 个（所以不用担心因为非零量太多直接变成指数级算法）。

第二步

把实例 I 拆成两部分， I_1 包含了解的整数部分（即 $\lfloor x \rfloor$ ）， I_2 包含了解的小数部分（即 $x - \lfloor x \rfloor$ ）。由于我们使用的 pattern 种数至多为 k ，那么小数部分物品的体积总和不超过 k 。

很容易发现, I_1 的最优解就是恰好放满 $\text{OPT}_{LP}(I_1)$ 个 bin, 那么容易有 $\text{OPT}_{LP}(I_1) + \text{OPT}_{LP}(I_2) = \text{OPT}_{LP}(I)$ 。

举个例子:

假如有 2 种物品 c_1, c_2 和 2 种 pattern。

第 1 个 pattern 有 3 个 c_1 与 1 个 c_2 ;

第 2 个 pattern 有 1 个 c_1 与 3 个 c_2 。

Configuration LP 的解为 2.5 个 pattern 1 与 1.5 个 pattern 2。

那么我们把 I 拆成两个部分,

I_1 里有 $3 \times 2 + 1 \times 1 = 7$ 个 c_1 和 $1 \times 2 + 3 \times 1 = 5$ 个 c_2 ,

I_2 里有 $3 \times 0.5 + 1 \times 0.5 = 2$ 个 c_1 和 $1 \times 0.5 + 3 \times 0.5 = 2$ 个 c_2 。

第三步

把 I_2 中的所有物品按体积总大到小排序, 设为 $d_1 \geq d_2 \geq \dots$ 。

我们把这些物品分堆: 首先找到最小的 n_1 , 把 d_1 到 d_{n_1} 分成第一堆, 且堆内物品体积总和至少为 2; 再找到最小的 n_2 , 把 d_{n_1+1} 到 d_{n_2} 分成第二堆, 且堆内体积总和至少为 2; ...这样分成 p 堆, 显然只有最后一堆的体积总和可能小于 2。

由于每个物品的体积都至多为 1, 每一堆的体积总和肯定小于 3。还容易发现, 由于物品是按体积从大到小排序的, 有 $n_1 \leq n_2 \leq \dots \leq n_{p-1}$ 。

接下来, 我们去掉第一堆和第 p 堆。在第 2 到 $p-1$ 堆中, 对于第 i 堆, 我们只留下最大的 n_{i-1} 个物品 (去掉剩下的 $n_i - n_{i-1}$ 个物品), 并且把这些物品的体积都放大到第 i 堆里最大的体积。将我们留下来的物品构成实例 I' 。

不难注意到, 如果我们将 I' 也进行分堆, 那么 I' 里第一堆的物品数和 I_2 里第一堆的物品数相同, 但体积都没有 I_2 第一堆的大, 其它堆也是如此。所以我们有 $\text{OPT}(I') \leq \text{OPT}(I_2)$ 。我们只要把 I' 作为新一轮迭代的实例进行迭代即可。

不过，我们要迭代多少轮呢？注意到 I_2 分堆后，每一堆的体积至少为 2，那么 I' 中体积不同的物品种数至多为 $\frac{c(I_2)}{2}$ 。别忘了我们在第二步中发现的结论：小数部分物品的体积总和不超过体积不同的物品种数。所以每一轮 I_2 的体积都会折半，那么 $\log c(I)$ 轮之后迭代就会结束。

最后我们再来看看被我们去掉的物品总体积是多少。

首先，我们去掉了第一堆和第 p 堆，这两堆的体积之和至多为 6。

再来看第 2 堆到第 $p-1$ 堆。对于第 i 堆，我们去掉了 $n_i - n_{i-1}$ 个物品，它们的体积均值不会超过 $\frac{3}{n_i}$ （只考虑小的值，均值会变小）。我们来求个和

$$\begin{aligned}
 & 6 + \sum_{i=2}^{p-1} (n_i - n_{i-1}) \frac{3}{n_i} \\
 = & 6 + 3 \sum_{i=2}^{p-1} \left(\frac{1}{n_i} + \frac{1}{n_i} + \cdots + \frac{1}{n_i} \right) \\
 \leq & 6 + 3 \sum_{i=2}^{p-1} \left(\frac{1}{n_{i-1}+1} + \frac{1}{n_{i-1}+2} + \cdots + \frac{1}{n_i} \right) \\
 \leq & 6 + 3 \sum_{i=1}^{n_{p-1}} \frac{1}{i}
 \end{aligned}$$

别忘了我们一开始就把体积小于 $\frac{1}{c(I)}$ 的物品拿走

了，那么 $n_{p-1} \leq 3 \nabla \cdot \frac{1}{c(I)} = 3c(I)$ ，那么去掉的物品总体积就是 $O(\log c(I))$ 的了。

我们最后再把这些去掉的物品 first fit 一下就好了。我们知道 first fit 近似比是 1.7 的，不会改变大 O 的结论。

回顾一下

每次迭代都会把当前实例 I 分成 I_1 和 I_2 。 I_1 里的物品由于恰好装满箱子，肯定是最优解的一部分，那么比最优解差的部分就来自于 I_2 中被去掉的物品。而 I_2 中被去掉的物品总体积为 $O(\log c(I))$ ，迭代最多进行 $\log c(I)$ 次，所以算法的结果就是 $\text{OPT}_{LP}(I) + O(\log^2 C(I)) \leq \text{OPT}_{LP}(I) + O(\log^2 \text{OPT}_{LP}(I))$ ，这就完成了证明。